



ULPGC
Universidad de
Las Palmas de
Gran Canaria



ESCUELA DE
INGENIERÍA INFORMÁTICA

Trabajo de Fin de Grado

Explicabilidad Forense de Tatuajes mediante Visión Artificial y modelos de lenguaje (LLM)

TITULACIÓN: Grado en Ciencia e Ingeniería de Datos

AUTOR: Víctor Blanco Dávila

TUTORIZADO POR:
David Freire Obregón

Junio 2026

SOLICITUD DE DEFENSA DE TRABAJO DE FIN DE TÍTULO

D. Víctor Blanco Dávila, autor del trabajo Explicabilidad Forense de Tatuajes mediante Visión Artificial y modelos de lenguaje (LLM), correspondiente a la titulación Grado en Ciencia e Ingeniería de Datos.

SOLICITA

que se inicie el procedimiento de defensa del mismo, para lo que se adjunta la documentación requerida, haciendo constar que

☐ se autoriza / ☒ no se autoriza la grabación en audio de la exposición y turno de preguntas.

Asimismo, con respecto al registro de la propiedad intelectual/industrial del TFT, declara que:

☐ Se ha iniciado o hay intención de iniciarlo (defensa no pública).

☒ No está previsto.

Y para que así conste firma la presente. (fecha en firma electrónica)

El/La estudiante

Fdo. _____

A rellenar y firmar **obligatoriamente** por el/la/los/las tutores

En relación con la presente solicitud, se informa: (firmar donde corresponda)

Positivamente (en caso de detección de copia, esta firma quedará invalidada)

Fdo. _____

Negativamente (justificación en TFT05)

Fdo. _____

DIRECTOR DE LA ESCUELA DE INGENIERÍA INFORMÁTICA

Agradecimientos

Con este trabajo termina una etapa que ha ocupado una parte muy importante de mi vida durante los últimos años. Mirando atrás, me doy cuenta de que llegar hasta aquí ha sido posible gracias a muchas personas que me han acompañado de una forma u otra durante el camino.

Quiero agradecer a mi tutor, David Freire Obregón, por su ayuda durante el desarrollo de este proyecto. Sus recomendaciones y observaciones me han servido para enfocar mejor muchas de las decisiones tomadas a lo largo del trabajo.

A mis padres y a mis hermanos, gracias por todo. Por el apoyo, por la confianza y por estar siempre ahí incluso cuando las cosas no salían como esperaba. Este trabajo lleva mi nombre, pero detrás hay mucho esfuerzo y sacrificio que también os pertenece a vosotros.

También quiero acordarme de mis amigos de toda la vida. Hemos compartido muchas etapas juntos y la universidad ha sido una más. Gracias por seguir estando ahí después de tantos años.

A todas las personas que conocí durante la carrera y que empezaron siendo compañeros de clase. Entre prácticas, trabajos en grupo, exámenes y horas interminables en la biblioteca, muchas de esas personas terminaron convirtiéndose en amigos que espero conservar mucho tiempo.

No puedo dejar de mencionar mi año de Erasmus en Praga. Cuando empecé no imaginaba lo importante que acabaría siendo esa experiencia. Me permitió conocer a personas increíbles, vivir situaciones que jamás habría experimentado de otra forma y crecer tanto personal como académicamente. Sin duda, es una de las mejores decisiones que he tomado durante estos años.

Por último, gracias a la Universidad de Las Palmas de Gran Canaria, a la Escuela de Ingeniería Informática y a todos los profesores que han formado parte de mi formación durante esta etapa.

Y gracias, en general, a todas las personas que han estado presentes durante

estos años. Cada una, de una forma u otra, ha contribuido a que hoy pueda cerrar esta etapa y comenzar la siguiente.

Resumen

La identificación y análisis de tatuajes constituye una herramienta de gran utilidad dentro del ámbito forense y biométrico, especialmente en situaciones donde otros elementos identificativos, como el rostro, no se encuentran disponibles o presentan una calidad insuficiente. Sin embargo, la descripción manual de tatuajes continúa siendo un proceso altamente dependiente de la experiencia del analista, pudiendo introducir subjetividad, inconsistencias y dificultades de trazabilidad en contextos periciales.

Este Trabajo de Fin de Grado presenta el desarrollo de un sistema orientado a la generación automática de descripciones forenses explicables de tatuajes mediante técnicas de visión artificial y modelos de lenguaje multimodales. El trabajo se divide en dos enfoques principales. En el primero, se emplea una base de datos con máscaras de segmentación para extraer características cuantitativas relacionadas con la geometría, posición, forma y apariencia visual de los tatuajes. Estas características son posteriormente utilizadas junto con modelos multimodales para generar informes forenses estructurados en lenguaje natural.

En el segundo enfoque, se estudia el comportamiento de distintos modelos multimodales sobre imágenes sin segmentación previa, evaluando directamente su capacidad para identificar características relevantes de los tatuajes mediante preguntas categóricas y descripciones automáticas. Para ello, se comparan diferentes modelos de visión-lenguaje, analizando su rendimiento y sus limitaciones en tareas relacionadas con tamaño, color, presencia de texto y número de tatuajes.

Durante el desarrollo del proyecto se analizaron diferentes estrategias de extracción de características, generación de prompts y corrección de errores en modelos multimodales, priorizando en todo momento la interpretabilidad y la robustez del sistema. Los resultados obtenidos muestran que la combinación de características visuales explicables junto con modelos multimodales permite generar descripciones coherentes y útiles dentro de un contexto forense, al mismo tiempo que pone de manifiesto las limitaciones actuales de este tipo de modelos en tareas de interpretación visual compleja.

Abstract

Tattoo identification and analysis represent a valuable tool within forensic and biometric contexts, especially in situations where other identifying elements, such as facial information, are unavailable or insufficient. However, manual tattoo description remains a highly subjective process that strongly depends on the analyst’s experience, which may introduce inconsistencies and reduce traceability in forensic environments.

This Final Degree Project presents the development of a system aimed at generating explainable forensic tattoo descriptions by combining computer vision techniques and multimodal large language models. The work is divided into two main approaches. The first approach uses a segmented tattoo dataset to extract quantitative features related to geometry, spatial distribution, shape and visual appearance. These features are later combined with multimodal models in order to generate structured forensic reports in natural language.

The second approach studies the behavior of different multimodal vision-language models when operating directly on non-segmented tattoo images. Several models are evaluated according to their ability to identify relevant tattoo characteristics through categorical questions and automatic descriptions. The analysis focuses on attributes such as tattoo size, color, text presence and tattoo count.

Throughout the project, multiple strategies for feature extraction, prompt engineering and hallucination control in multimodal models were explored, prioritizing interpretability and system robustness. The obtained results show that combining explainable visual features with multimodal language models can generate coherent and useful forensic descriptions, while also highlighting the current limitations of these models in complex visual interpretation tasks.

Índice general

1. Introducción	1
2. Estado actual y objetivos iniciales	4
2.1. Motivación y antecedentes	4
2.2. Objetivos	5
3. Aportaciones del trabajo	7
3.1. Principales aportaciones	7
3.2. Competencias específicas	7
3.3. Alineamiento con los objetivos de desarrollo sostenible	8
4. Desarrollo	10
4.1. Metodología	10
4.2. Entorno de trabajo y tecnologías utilizadas	12
4.2.1. Lenguaje de programación	12
4.2.2. Bibliotecas utilizadas	12
4.2.3. Frameworks de aprendizaje profundo	13
4.2.4. Modelos multimodales utilizados	13
4.2.5. Almacenamiento y organización del proyecto	14
4.3. Bases de datos utilizadas	14
4.3.1. HDA Semi-synthetic Tattoo Database	14
4.3.2. Tattoo-YOLO	16
4.3.3. Comparación entre ambas bases de datos	17
4.3.4. Selección de los subconjuntos utilizados	17
4.4. Arquitectura general del sistema	18
4.4.1. Primer enfoque: generación de informes forenses	18
4.4.2. Segundo enfoque: evaluación de modelos multimodales	18
4.4.3. Conjunto de referencia	19
4.5. Extractor de características sobre imágenes segmentadas	19
4.5.1. Objetivos del extractor	19
4.5.2. Procesamiento inicial de imágenes y máscaras	19
4.5.3. Separación de regiones semánticas	20
4.5.4. Limpieza de la máscara del tatuaje	21
4.5.5. Características espaciales	22

4.5.6. Características de forma	24
4.5.7. Características de apariencia	27
4.5.8. Estructura final de las características	30
4.5.9. Procesamiento por lotes	31
4.5.10. Resumen del sistema de generación de informes	32
4.6. Generación de informes forenses mediante modelos multimodales	32
4.6.1. Objetivos del sistema de generación	32
4.6.2. Selección del modelo multimodal	33
4.6.3. Preparación de la entrada	33
4.6.4. Transformación de características cuantitativas	34
4.6.5. Refinamiento del prompt y control de alucinaciones	35
4.6.6. Estructura del informe generado	37
4.6.7. Generación automática por lotes	38
4.6.8. Limitaciones detectadas	39
4.6.9. Resumen del sistema de generación de informes	39
4.7. Evaluación de modelos multimodales sobre imágenes no segmentadas	40
4.7.1. Selección de las variables evaluadas	41
4.7.2. Construcción del conjunto de referencia	41
4.7.3. Proceso y criterios de etiquetado	41
4.7.4. Almacenamiento de las etiquetas	42
4.7.5. Importancia del conjunto de referencia	42
4.7.6. Modelos evaluados	43
4.7.7. Diseño de las preguntas	43
4.7.8. Exploración mediante preguntas abiertas	44
4.7.9. Pipeline de evaluación	45
4.7.10. Normalización de respuestas	45
4.7.11. Almacenamiento de resultados	45
4.7.12. Resumen del proceso de evaluación	46
4.8. Consideraciones finales sobre el desarrollo	46
5. Resultados	47
5.1. Resultados del extractor de características	47
5.2. Resultados de generación de informes forenses	49
5.2.1. Calidad general de los informes	49
5.2.2. Ejemplo de informe generado	50
5.2.3. Análisis cualitativo	51
5.2.4. Limitaciones observadas	51
5.3. Resultados de evaluación multimodal	52
5.3.1. Análisis por variable	53
5.3.2. Selección del modelo final	55
5.3.3. Análisis detallado de Qwen2-VL	55
5.3.4. Evaluación cualitativa mediante preguntas abiertas	59
5.4. Grado de consecución de los objetivos	61
6. Conclusiones y trabajos futuros	62

6.1. Conclusiones	62
6.2. Trabajos futuros	63
6.3. Uso de la Inteligencia Artificial	64

Índice de Algoritmos

4.1. Separación de regiones a partir de la máscara original.	20
4.2. Detección de componentes conectados.	21
4.3. Obtención de la caja envolvente.	23
4.4. Obtención del contorno principal.	25
4.5. Estructura simplificada de las características generadas.	31
4.6. Restricciones incorporadas al prompt final.	36
4.7. Estructura simplificada del conjunto de referencia.	42
4.8. Ejemplo de preguntas utilizadas durante la evaluación.	44

Índice de figuras

4.1. Ejemplo de imagen original y máscara de segmentación de la base HDA. . .	15
4.2. Ejemplo de imagen perteneciente a la base Tattoo-YOLO y su correspondiente anotación mediante caja delimitadora.	16
4.3. Separación de las regiones semánticas presentes en la máscara HDA.	21
4.4. Ejemplo de caja envolvente calculada a partir de la máscara del tatuaje. . . .	23
4.5. Características geométricas calculadas sobre la región tatuada.	27
4.6. Proceso de generación del recorte a partir de la región tatuada.	29
5.1. Ejemplo de salida generada por el extractor de características.	48
5.2. Ejemplo de tatuaje utilizado para la generación automática del informe. . . .	50
5.3. Comparación de precisión entre los modelos evaluados para cada variable. . .	54
5.4. Precisión obtenida por Qwen2-VL para cada variable evaluada.	55
5.5. Matriz de confusión para la variable <code>tattoo_size</code>	56
5.6. Matriz de confusión para la variable <code>contains_text</code>	58
5.7. Ejemplo de tatuaje utilizado durante la evaluación mediante preguntas abiertas.	60

Índice de cuadros

3.1. Grado de relación del TFT con los objetivos de desarrollo sostenible.	8
4.1. Comparación entre las bases de datos utilizadas.	17
4.2. Variables evaluadas en la segunda parte del proyecto.	41
4.3. Modelos multimodales evaluados.	43
5.1. Grupos de características obtenidos por el extractor.	49
5.2. Precisión obtenida por cada modelo multimodal.	52
5.3. Comparación entre precisión estricta y precisión con tolerancia para la variable	
tattoo_size.	57

Capítulo 1

Introducción

La identificación de personas ha sido históricamente uno de los principales objetivos dentro del ámbito forense y biométrico. A lo largo de los años se han desarrollado numerosas técnicas para facilitar este proceso, desde métodos tradicionales basados en características físicas visibles hasta sistemas biométricos avanzados apoyados en inteligencia artificial. Actualmente, modalidades como el reconocimiento facial, las huellas dactilares o el reconocimiento del iris constituyen algunas de las herramientas más utilizadas debido a su elevada capacidad discriminativa y a los avances tecnológicos alcanzados durante las últimas décadas.

Sin embargo, estas modalidades no siempre pueden emplearse de forma efectiva. La baja calidad de las imágenes, las condiciones de iluminación, el deterioro de la evidencia o incluso la ausencia parcial o total de determinadas características biométricas pueden dificultar considerablemente el proceso de identificación. En este tipo de situaciones surge la necesidad de recurrir a elementos biométricos complementarios capaces de aportar información adicional y mejorar el análisis realizado por los especialistas.

Entre estos elementos, los tatuajes representan una fuente de información especialmente valiosa. Sus características visuales suelen ser distintivas y permanecen relativamente estables a lo largo del tiempo. Su presencia puede facilitar procesos de identificación humana tanto en investigaciones policiales como en contextos forenses relacionados con desapariciones, reconocimiento de víctimas o análisis de imágenes procedentes de sistemas de videovigilancia. Además, muchos tatuajes incorporan patrones, símbolos, texto o elementos gráficos que pueden resultar lo suficientemente característicos como para asociar una imagen a una persona concreta o reducir significativamente el número de posibles coincidencias.

A pesar de su utilidad, el análisis de tatuajes continúa siendo una tarea compleja y en gran medida dependiente de la experiencia del analista humano. La descripción manual suele realizarse utilizando lenguaje natural, lo que introduce inevitablemente cierto grado de subjetividad. Dos especialistas pueden describir un mismo tatuaje de formas diferentes dependiendo de su experiencia previa, del nivel de detalle considerado relevante o incluso de la terminología empleada durante el análisis. Esta falta de estandarización puede generar inconsistencias entre informes, dificultar búsquedas posteriores en bases de datos y reducir la trazabilidad de los procesos de identificación.

Por otra parte, el creciente volumen de imágenes digitales disponible en entornos policiales y forenses hace cada vez más difícil realizar análisis completamente manuales de forma eficiente. Como consecuencia, la automatización de determinadas tareas relacionadas con la identificación y descripción de tatuajes se ha convertido en una línea de investigación de gran interés dentro de la visión artificial y la biometría forense.

Durante los últimos años, los avances en inteligencia artificial han permitido desarrollar modelos capaces de interpretar información visual con niveles de precisión cada vez más elevados. En particular, la aparición de modelos multimodales basados en arquitecturas visión-lenguaje ha supuesto un cambio significativo en la forma en que los sistemas de inteligencia artificial analizan imágenes y generan descripciones en lenguaje natural. Los modelos más recientes son capaces de identificar objetos, interpretar escenas complejas e incluso responder preguntas relacionadas con el contenido visual de una imagen.

Estas capacidades abren nuevas posibilidades dentro del ámbito forense, donde la generación automática de descripciones visuales puede servir como herramienta de apoyo para los analistas humanos. No obstante, el uso de modelos multimodales en contextos sensibles también plantea importantes desafíos. Uno de los principales es la aparición de alucinaciones, entendidas como la generación de información incorrecta, exagerada o directamente inventada. En aplicaciones forenses, donde la fiabilidad y la trazabilidad de las decisiones son aspectos fundamentales, este tipo de errores puede comprometer seriamente la utilidad práctica de un sistema.

Por este motivo, la explicabilidad adquiere un papel especialmente relevante. No basta con que un modelo produzca una descripción aparentemente coherente; también es necesario comprender qué información visual está utilizando y hasta qué punto las conclusiones generadas pueden justificarse mediante características objetivas y medibles. La incorporación de mecanismos explicables reduce la dependencia de interpretaciones subjetivas y facilita que los resultados obtenidos puedan ser revisados y validados por expertos humanos.

En este contexto, este Trabajo de Fin de Grado plantea el desarrollo de un sistema orientado a la generación automática de descripciones forenses explicables de tatuajes mediante técnicas de visión artificial y modelos multimodales. El objetivo principal consiste en combinar información visual cuantitativa con modelos de lenguaje para generar informes estructurados en lenguaje natural manteniendo un grado adecuado de interpretabilidad.

Para ello, el proyecto se divide en dos enfoques principales. El primero parte de una base de datos de imágenes de tatuajes acompañadas de máscaras de segmentación. A partir de estas máscaras se extraen diferentes características cuantitativas relacionadas con la geometría, la forma, la posición y la apariencia visual de los tatuajes. Posteriormente, dichas características se utilizan junto con modelos multimodales para generar descripciones forenses estructuradas y justificadas mediante información objetiva extraída directamente de la imagen.

El segundo enfoque estudia el comportamiento de distintos modelos multimodales trabajando directamente sobre imágenes sin segmentación previa. En este caso, el objetivo consiste en analizar su capacidad para identificar automáticamente determinadas características relevantes de los tatuajes, como el número de tatuajes presentes, el tamaño aproximado, la presencia de texto o la tonalidad predominante. Este análisis permite evaluar tanto las capa-

ciudades actuales de los modelos visión-lenguaje como sus limitaciones dentro de un contexto forense.

A lo largo del desarrollo del proyecto se exploraron diferentes estrategias relacionadas con la extracción de características, el diseño de prompts y el control de alucinaciones en modelos multimodales. Asimismo, se realizaron múltiples pruebas experimentales con distintos modelos de visión-lenguaje para analizar la calidad de las descripciones generadas y el grado de coherencia entre la información visual observada y el texto producido.

El objetivo final del trabajo no consiste en sustituir el criterio de un analista forense, sino en estudiar el potencial de estas tecnologías como herramientas de apoyo para facilitar tareas de descripción, análisis y documentación de tatuajes. La combinación de características visuales extraídas automáticamente y modelos multimodales permite generar informes más consistentes, reproducibles y trazables, reduciendo parcialmente la subjetividad asociada al análisis manual tradicional.

La memoria se organiza de la siguiente manera. En primer lugar, se presenta el estado actual del problema y los objetivos planteados para el desarrollo del trabajo. Posteriormente, se describen las principales aportaciones realizadas, así como las competencias y objetivos de desarrollo sostenible relacionados con el proyecto. A continuación, se detalla el desarrollo técnico llevado a cabo, incluyendo la metodología utilizada, los procesos de extracción de características, los modelos multimodales evaluados y los distintos experimentos realizados. Finalmente, se presentan los resultados obtenidos, las conclusiones derivadas del trabajo y las posibles líneas futuras de investigación.

Capítulo 2

Estado actual y objetivos iniciales

2.1. Motivación y antecedentes

Los tatuajes han adquirido una importancia creciente dentro del ámbito forense como elemento biométrico complementario. Aunque no tienen la capacidad identificativa de modalidades como las huellas dactilares o el reconocimiento facial, sí que poseen características visuales relativamente estables y, en muchos casos, altamente distintivas. Esta combinación los convierte en una fuente de información útil para investigaciones policiales, identificación de víctimas y procesos de comparación forense.

Durante los últimos años se han desarrollado numerosos trabajos relacionados con la detección automática de tatuajes, la segmentación de regiones tatuadas y la recuperación de imágenes similares. El avance de las técnicas de visión artificial y aprendizaje profundo ha permitido mejorar significativamente el rendimiento de estos sistemas, especialmente mediante el uso de redes neuronales convolucionales y modelos de aprendizaje profundo especializados en análisis visual.

Sin embargo, la mayor parte de las investigaciones existentes se centran en tareas de detección, clasificación o recuperación de imágenes, mientras que la generación automática de descripciones interpretables sigue siendo un problema menos explorado. En muchos casos los sistemas son capaces de identificar determinadas características visuales, pero no proporcionan explicaciones claras sobre los criterios utilizados para llegar a esas conclusiones. Esta limitación resulta especialmente relevante en contextos forenses, donde la trazabilidad y la interpretabilidad de los resultados son aspectos fundamentales.

Por otra parte, el análisis manual de tatuajes sigue dependiendo en gran medida de la experiencia del especialista encargado de realizar la evaluación. La ausencia de criterios completamente estandarizados puede dar lugar a descripciones diferentes para un mismo tatuaje, dificultando la comparación entre informes y la automatización de búsquedas en bases de datos.

Además, los modelos multimodales visión-lenguaje han experimentado un avance notable

en los últimos años. Estos sistemas han demostrado una gran capacidad para interpretar contenido visual y generar descripciones en lenguaje natural, lo que abre nuevas posibilidades para el desarrollo de herramientas de apoyo al análisis forense.

Aunque cabe recalcar que la utilización de este tipo de modelos también plantea desafíos importantes. Entre ellos destaca la aparición de alucinaciones y la dificultad para justificar adecuadamente las conclusiones generadas. Es por ello que la incorporación de mecanismos explicables es un aspecto clave cuando se quiere aplicar estas tecnologías en entornos donde la fiabilidad de los resultados resulta especialmente importante.

En este contexto surge la motivación principal de éste trabajo. El proyecto estudia la combinación de técnicas de visión artificial y modelos multimodales para generar descripciones forenses de tatuajes apoyadas en características visuales objetivas extraídas directamente de las imágenes. De esta forma se pretende reducir parcialmente la subjetividad asociada al análisis manual y estudiar el potencial real de estas tecnologías como herramientas de apoyo para especialistas humanos.

2.2. Objetivos

El objetivo general de este Trabajo de Fin de Grado consiste en desarrollar y evaluar un sistema capaz de generar descripciones forenses explicables de tatuajes, combinando técnicas de visión artificial y modelos multimodales.

Para alcanzar este objetivo general se definieron una serie de objetivos específicos relacionados con el procesamiento de imágenes, la extracción de características visuales y la generación automática de descripciones en lenguaje natural.

En primer lugar, se planteó la integración y preparación de un conjunto de imágenes de tatuajes acompañado de máscaras de segmentación. El uso de imágenes segmentadas permite trabajar directamente sobre la región tatuada y facilita la obtención de información visual relevante sin necesidad de desarrollar un sistema completo de detección automática.

Otro de los objetivos específicos fue diseñar e implementar un extractor de características capaz de obtener información cuantitativa sobre diferentes propiedades del tatuaje. Entre estas características se incluyen aspectos relacionados con la geometría, la forma, la posición, el contraste y la complejidad visual.

A partir de estas características, se propuso estudiar el uso de modelos multimodales para generar descripciones automáticas en lenguaje natural. El objetivo no era únicamente producir texto descriptivo, sino incorporar información visual objetiva que permitiera justificar parcialmente las conclusiones generadas por el sistema.

Con el fin de mejorar la coherencia y el control de las respuestas producidas por los modelos, también se planteó el diseño de estrategias de *prompt engineering* adaptadas al contexto forense. Estas estrategias debían favorecer la generación de descripciones más estructuradas y reducir, en la medida de lo posible, la aparición de información incorrecta o insuficientemente justificada.

Además, se definió como objetivo la evaluación experimental de distintos modelos visión-lenguaje aplicados al análisis de tatuajes. Esta evaluación incluye tanto la generación de informes a partir de características previamente extraídas como el análisis directo de imágenes sin segmentación previa.

Otro objetivo consistió en estudiar las capacidades y limitaciones de estos modelos en tareas relacionadas con la identificación de atributos visuales de los tatuajes. Entre estos atributos encontramos: el número de tatuajes presentes, el tamaño aproximado, la presencia de texto o la tonalidad predominante.

Finalmente, el proyecto busca de forma global analizar el potencial de los sistemas multi-modales como herramientas de apoyo para especialistas humanos, evaluando hasta qué punto la combinación de características visuales explicables y modelos de lenguaje puede contribuir a generar descripciones más consistentes, trazables y comprensibles dentro de un entorno forense.

Capítulo 3

Aportaciones del trabajo

3.1. Principales aportaciones

La principal aportación de este Trabajo de Fin de Grado consiste en explorar la generación de descripciones forenses de tatuajes combinando características visuales explicables y modelos multimodales de lenguaje. Aunque ya existen trabajos centrados en la detección, segmentación o clasificación de tatuajes, la generación de informes interpretables sigue siendo un área menos estudiada.

Frente a enfoques puramente generativos, éste sistema incorpora información cuantitativa extraída directamente de las imágenes para apoyar la generación de descripciones en lenguaje natural. Este planteamiento permite relacionar parte del contenido del informe con características objetivas del tatuaje, favoreciendo una mayor trazabilidad de los resultados.

Otra aportación relevante es la evaluación comparativa de distintos modelos visión-lenguaje aplicados al análisis de tatuajes. Los experimentos llevados a cabo permitieron identificar sus fortalezas y limitaciones en tareas relacionadas con la descripción visual, la identificación de atributos y la generación de respuestas en un contexto forense.

Finalmente, el trabajo aporta una evaluación práctica sobre las posibilidades actuales de los modelos multimodales en aplicaciones forenses, analizando aspectos como la interpretabilidad de los resultados, la aparición de alucinaciones y la utilidad real de estos sistemas como herramientas de apoyo para especialistas humanos.

3.2. Competencias específicas

El desarrollo de este Trabajo de Fin de Grado ha permitido aplicar conocimientos relacionados con la visión artificial, el aprendizaje automático y los modelos multimodales de lenguaje dentro de un problema real de análisis forense.

Durante el proyecto fue necesario diseñar procedimientos de extracción y procesamiento de información visual, integrar diferentes herramientas software y evaluar experimentalmente el comportamiento de varios modelos de inteligencia artificial. Todo ello requirió combinar conocimientos teóricos con una importante componente práctica orientada al desarrollo de un sistema funcional.

Asimismo, el trabajo ha contribuido al desarrollo de competencias relacionadas con el análisis crítico de resultados, la identificación de limitaciones técnicas y la interpretación de experimentos realizados sobre conjuntos de datos reales.

Por último, la elaboración de la memoria y la presentación de los resultados han permitido reforzar competencias vinculadas con la comunicación técnica, la documentación de proyectos y la capacidad para justificar de forma razonada las decisiones adoptadas durante el desarrollo del trabajo.

3.3. Alineamiento con los objetivos de desarrollo sostenible

Cuadro 3.1: Grado de relación del TFT con los objetivos de desarrollo sostenible.

ODS	Grado de relación			
	0 No procede	1 Bajo	2 Medio	3 Alto
1 Fin de la pobreza	X			
2 Hambre cero	X			
3 Salud y bienestar		X		
4 Educación de calidad		X		
5 Igualdad de género	X			
6 Agua limpia y saneamiento	X			
7 Energía asequible y no contaminante	X			
8 Trabajo decente y crecimiento económico		X		
9 Industria, innovación e infraestructuras				X
10 Reducción de las desigualdades	X			
11 Ciudades y comunidades sostenibles	X			
12 Producción y consumo responsables	X			
13 Acción por el clima	X			
14 Vida submarina	X			
15 Vida de ecosistemas terrestres	X			
16 Paz, justicia e instituciones sólidas			X	
17 Alianzas para lograr los objetivos		X		

El trabajo mantiene una relación especialmente relevante con el Objetivo de Desarrollo Sostenible 9, relacionado con industria, innovación e infraestructuras. El proyecto explora la

aplicación de técnicas actuales de inteligencia artificial, visión artificial y modelos multimodales a un problema real dentro del ámbito forense. La combinación de procesamiento visual y generación automática de lenguaje natural representa una línea de investigación alineada con el desarrollo de tecnologías innovadoras y sistemas inteligentes capaces de asistir a los profesionales en tareas especializadas.

También guarda relación con el Objetivo de Desarrollo Sostenible 16, orientado a promover instituciones más eficaces, transparentes y accesibles. Aunque se trata de un trabajo académico, el estudio de sistemas explicables para el análisis forense puede contribuir a mejorar la trazabilidad y la consistencia de determinados procesos de identificación y documentación basados en evidencia visual.

El sistema desarrollado no pretende sustituir el criterio de los especialistas humanos, sino explorar el potencial de la inteligencia artificial como herramienta de apoyo. En este sentido, el trabajo pone especial énfasis en aspectos como la interpretabilidad de los resultados, el control de las alucinaciones y la justificación de las descripciones generadas, cuestiones especialmente importantes cuando se trabaja con aplicaciones relacionadas con el ámbito forense.

Capítulo 4

Desarrollo

4.1. Metodología

Este proyecto se desarrolló siguiendo una metodología iterativa e incremental. Desde el inicio se planteó como un proyecto experimental en el que muchas de las decisiones dependían de los resultados obtenidos durante las distintas fases de desarrollo. Por este motivo, no se partió de una solución completamente definida, sino de una idea general que fue evolucionando a medida que se realizaban pruebas y se analizaban los resultados.

La idea principal consistía en combinar dos tipos de información complementaria. Por un lado, características visuales obtenidas directamente de las imágenes mediante técnicas de procesamiento de imagen y extracción de características. Por otro, modelos multimodales capaces de interpretar información visual y generar descripciones en lenguaje natural. El objetivo era aprovechar las ventajas de ambos enfoques para generar informes más explicables y fáciles de justificar que los obtenidos mediante un modelo puramente generativo.

A medida que avanzó el proyecto fue necesario revisar algunas decisiones iniciales. Determinadas características que en un principio parecían útiles no ofrecían resultados suficientemente consistentes al aplicarlas sobre los conjuntos de datos disponibles. En estos casos se optó por simplificar el sistema y mantener únicamente aquellas métricas que podían calcularse de forma fiable y que aportaban información relevante para la generación de los informes.

El trabajo terminó organizándose en dos líneas principales. La primera se desarrolló utilizando una base de datos con máscaras de segmentación, lo que permitió trabajar directamente sobre la región tatuada y extraer características cuantitativas relacionadas con la forma, la posición, el contraste y la complejidad visual del tatuaje. Estas características se utilizaron posteriormente para generar informes forenses mediante un modelo multimodal.

La segunda línea surgió al trabajar con una base de datos anotada en formato YOLO. En un principio se buscaba reutilizar el extractor desarrollado en la primera parte del proyecto, pero las anotaciones disponibles no permitían separar de forma fiable la tinta del tatuaje del resto de elementos presentes en la imagen. Como consecuencia, esta parte del trabajo

evolucionó hacia una evaluación directa de distintos modelos visión-lenguaje sobre imágenes sin segmentación previa.

De esta forma, el proyecto terminó combinando un enfoque basado en características explicables con un segundo enfoque centrado en evaluar las capacidades de los modelos multimodales para identificar atributos visuales directamente a partir de las imágenes.

Principales fases del desarrollo:

- Estudio de las bases de datos y de los formatos de anotación disponibles.
- Preparación del entorno de trabajo.
- Desarrollo del extractor de características para imágenes segmentadas.
- Validación visual de las características obtenidas.
- Generación de ficheros estructurados para almacenar resultados.
- Integración de las características con modelos multimodales para la generación de informes.
- Diseño y refinamiento de prompts orientados al ámbito forense.
- Adaptación del trabajo a una segunda base de datos sin segmentación.
- Creación de etiquetas manuales para la evaluación.
- Comparación experimental entre distintos modelos visión-lenguaje.
- Análisis de errores, limitaciones y posibles mejoras.

Durante todo el proceso se revisaron continuamente los resultados obtenidos. No solo se comprobaba que el código funcionara correctamente, sino también que las salidas generadas fueran coherentes con los objetivos del proyecto. Esta revisión permitió detectar problemas relacionados con interpretaciones excesivas por parte de los modelos multimodales, lo que llevó a modificar y restringir progresivamente los prompts utilizados.

También se intentó mantener una estructura modular para facilitar la realización de pruebas independientes. Para ello, las diferentes tareas del proyecto se organizaron en bloques separados dedicados a la extracción de características, generación de informes, evaluación de modelos y análisis de resultados. Esta organización simplificó la experimentación y permitió repetir pruebas concretas sin necesidad de ejecutar todo el sistema completo.

En conjunto, la metodología seguida fue evolucionando conforme avanzaba el proyecto. Muchas de las decisiones adoptadas surgieron a partir de los resultados obtenidos durante las pruebas realizadas, lo que permitió adaptar el sistema tanto a las características de las bases de datos utilizadas como a las capacidades reales de los modelos multimodales evaluados.

4.2. Entorno de trabajo y tecnologías utilizadas

La mayor parte del desarrollo se realizó en Google Colab. Este entorno permitió trabajar cómodamente con los distintos conjuntos de datos utilizados durante el proyecto y ejecutar modelos multimodales sin necesidad de disponer de hardware especializado en local. Además, la integración con Google Drive facilitó el almacenamiento de imágenes, notebooks, características extraídas y resultados experimentales.

Las tareas que implicaban la ejecución de modelos multimodales se realizaron utilizando instancias con GPU NVIDIA Tesla T4 proporcionadas por Google Colab. El uso de GPU resultó especialmente importante durante la generación de informes y la evaluación de modelos sobre conjuntos completos de imágenes, reduciendo considerablemente los tiempos de procesamiento.

4.2.1. Lenguaje de programación

Todo el desarrollo se llevó a cabo utilizando Python. La elección de este lenguaje estuvo motivada principalmente por la disponibilidad de bibliotecas especializadas para visión artificial, procesamiento de imágenes y modelos multimodales, además de su sencillez para la integración con herramientas de análisis de datos y aprendizaje profundo.

4.2.2. Bibliotecas utilizadas

A lo largo del proyecto se utilizaron diferentes bibliotecas en función de las tareas realizadas.

4.2.2.1. OpenCV

OpenCV fue la herramienta principal para el procesamiento de imágenes y máscaras de segmentación. Se utilizó para obtener contornos, calcular cajas envolventes, extraer regiones de interés y generar gran parte de las características geométricas empleadas posteriormente en los informes.

4.2.2.2. NumPy

NumPy se empleó para realizar cálculos sobre las imágenes y las máscaras procesadas, así como para gestionar las estructuras de datos generadas durante la extracción de características.

4.2.2.3. Pandas

Con Pandas se realizaron tareas como almacenar y organizar los resultados obtenidos durante las distintas fases del proyecto. También permitió generar y manipular los ficheros CSV utilizados posteriormente en la evaluación de los modelos.

4.2.2.4. Matplotlib

Matplotlib resultó útil durante las fases de validación y análisis visual. Se empleó para representar imágenes, máscaras, regiones segmentadas y resultados experimentales, facilitando la detección de errores y la interpretación de los datos obtenidos.

4.2.3. Frameworks de aprendizaje profundo

4.2.3.1. PyTorch

PyTorch fue el framework utilizado para cargar y ejecutar los modelos multimodales empleados en el proyecto. Aunque no se entrenaron modelos desde cero, su uso fue fundamental para realizar inferencias sobre imágenes y gestionar la ejecución de los modelos en GPU.

4.2.3.2. Transformers

La biblioteca Transformers de Hugging Face permitió acceder de forma sencilla a los distintos modelos visión-lenguaje evaluados durante el trabajo. Gracias a ella fue posible cargar modelos preentrenados, preparar las entradas multimodales y generar respuestas a partir de imágenes y texto.

4.2.4. Modelos multimodales utilizados

En este trabajo se probaron varios modelos visión-lenguaje con el objetivo de estudiar su comportamiento en tareas relacionadas con el análisis de tatuajes.

Los principales modelos utilizados fueron:

- Moondream2
- LLaVA 1.5 7B
- Qwen2-VL 2B Instruct
- Qwen2.5-VL

Cada uno de ellos se empleó en distintas fases del proyecto. Algunos fueron utilizados durante las pruebas iniciales de generación de descripciones, mientras que otros formaron

parte de la evaluación comparativa realizada sobre la base de datos Tattoo-YOLO o se utilizaron para la generación de informes forenses.

4.2.5. Almacenamiento y organización del proyecto

Todos los recursos generados durante el desarrollo se almacenaron en Google Drive. La estructura de trabajo se organizó en diferentes notebooks dedicados a tareas concretas, como la extracción de características, la generación de informes, la evaluación de modelos o el análisis de resultados.

Esta organización permitió mantener separadas las distintas fases del proyecto, facilitar la depuración de errores y repetir experimentos concretos sin necesidad de ejecutar nuevamente todo el flujo de trabajo.

4.3. Bases de datos utilizadas

Durante el desarrollo del proyecto se utilizaron dos bases de datos con características muy diferentes. Cada una de ellas se empleó para una parte concreta del trabajo y terminó dando lugar a dos enfoques distintos.

Por un lado, se trabajó con una base de datos que proporcionaba máscaras de segmentación precisas para cada tatuaje. Esto permitió extraer características visuales directamente de la región tatuada y desarrollar el sistema de generación de informes explicables.

Por otro lado, se utilizó una segunda base de datos formada por imágenes reales anotadas mediante bounding boxes. Aunque este conjunto de datos no permitía realizar una extracción tan detallada de características, resultó más adecuado para evaluar directamente el comportamiento de los modelos multimodales en situaciones más próximas a un escenario real.

4.3.1. HDA Semi-synthetic Tattoo Database

La primera base de datos utilizada fue la *HDA Semi-synthetic Tattoo Database*. Este conjunto de datos constituyó la base de la primera parte del proyecto, ya que proporcionaba tanto las imágenes como las máscaras de segmentación necesarias para extraer características visuales de forma precisa.

La principal ventaja de esta base de datos es que permite conocer exactamente qué píxeles pertenecen al tatuaje, cuáles corresponden a la piel y cuáles forman parte del fondo. Gracias a esta información fue posible calcular métricas geométricas y de apariencia directamente sobre la región tatuada sin necesidad de desarrollar previamente un sistema de segmentación.

En este trabajo se utilizó el conjunto `synthetic-tattoo-images`, compuesto por 5.500 imágenes junto con sus correspondientes máscaras.

Las máscaras permiten distinguir claramente tres regiones:

- Fondo
- Piel
- Tatuaje

Gracias a esta separación fue posible calcular características asociadas únicamente a la tinta del tatuaje y compararlas posteriormente con la piel sin tatuaje.



[0.2cm] Imagen original



[0.2cm] Máscara de segmentación

Ilustración 4.1: Ejemplo de imagen original y máscara de segmentación de la base HDA.

Además de facilitar la extracción de características, las máscaras resultaron muy útiles durante las fases iniciales del desarrollo para comprobar visualmente que los cálculos realizados por el extractor eran correctos.

Sin embargo, es una base de datos que presenta algunas limitaciones. Aunque las imágenes resultan visualmente realistas, se trata de imágenes semisintéticas generadas a partir de diferentes elementos visuales. Por este motivo, no reflejan completamente toda la variabilidad que puede encontrarse en fotografías reales obtenidas en contextos forenses o policiales.

4.3.2. Tattoo-YOLO

La segunda base de datos utilizada fue Tattoo-YOLO, un conjunto de imágenes reales de tatuajes anotadas para tareas de detección mediante el formato YOLO.

A diferencia de HDA, esta base de datos no proporciona máscaras de segmentación por píxel. En su lugar, cada imagen incluye una anotación que indica aproximadamente dónde se encuentra el tatuaje mediante una caja delimitadora (*bounding box*).

Todas las imágenes se encuentran redimensionadas a una resolución de 640×640 píxeles y disponen de sus correspondientes archivos de anotación.

Las etiquetas permiten localizar la región donde aparece el tatuaje, pero no identificar con precisión qué píxeles pertenecen realmente a la tinta. Esto supone una diferencia importante respecto a HDA, ya que muchas de las características utilizadas en la primera parte del proyecto dependen precisamente de esa información.

Por este motivo, características como el área exacta del tatuaje, el contraste entre piel y tinta o determinadas métricas geométricas no podían calcularse de forma fiable utilizando únicamente las anotaciones disponibles en esta base de datos.



[0.2cm] Imagen original



[0.2cm] Anotación mediante bounding box

Ilustración 4.2: Ejemplo de imagen perteneciente a la base Tattoo-YOLO y su correspondiente anotación mediante caja delimitadora.

Aun así, esta base de datos ofrecía una ventaja importante: todas las imágenes son fotografías reales. Como consecuencia, presentan una variabilidad mucho mayor en aspectos como la iluminación, la calidad de imagen, el tono de piel, el tamaño de los tatuajes o el entorno en el que fueron capturadas.

Inicialmente se estudió la posibilidad de adaptar el extractor de características desarrollado para HDA, pero las limitaciones de las anotaciones disponibles hicieron que este enfoque no fuera viable. A partir de ese momento, Tattoo-YOLO pasó a utilizarse principalmente como base de evaluación para comparar distintos modelos multimodales trabajando directamente sobre imágenes reales.

4.3.3. Comparación entre ambas bases de datos

La Tabla 4.1 resume las principales diferencias entre ambas bases de datos.

Cuadro 4.1: Comparación entre las bases de datos utilizadas.

Característica	HDA	Tattoo-YOLO
Tipo de imágenes	Semisintéticas	Reales
Número aproximado de imágenes	5.500	4.418
Tipo de anotación	Máscaras de segmentación	Etiquetas YOLO
Información disponible	Fondo, piel y tatuaje	Localización aproximada
Permite calcular área exacta de tinta	Sí	No
Permite calcular contraste piel-tatuaje	Sí	No
Uso principal en el proyecto	Extracción de características	Evaluación multimodal

En conjunto, ambas bases de datos resultaron complementarias. HDA permitió desarrollar la parte explicable del sistema gracias a la disponibilidad de máscaras de segmentación, mientras que Tattoo-YOLO proporcionó un entorno más adecuado para estudiar las capacidades reales de los modelos multimodales trabajando directamente sobre imágenes reales.

4.3.4. Selección de los subconjuntos utilizados

En el caso de HDA se trabajó con el conjunto completo de imágenes disponibles, ya que el objetivo principal era validar el extractor de características y generar informes sobre el mayor número posible de ejemplos.

Para Tattoo-YOLO se decidió utilizar únicamente la partición **test**, formada por 450 imágenes. Esta decisión estuvo motivada principalmente por la necesidad de realizar un proceso de etiquetado manual que sirviera posteriormente como referencia para la evaluación de los modelos multimodales.

Aunque la base de datos completa contiene más de 4.000 imágenes, etiquetar manualmente la totalidad del conjunto habría supuesto una carga de trabajo excesiva. La partición **test**

proporcionaba un subconjunto suficientemente amplio para realizar la evaluación y, al mismo tiempo, mantenía una dimensión manejable para llevar a cabo el proceso de anotación manual.


Sobre estas imágenes se generaron etiquetas relacionadas con la presencia de tatuajes, el número de tatuajes visibles, el tamaño aproximado, el color predominante y la presencia de texto. Estas anotaciones se utilizaron posteriormente para comparar de forma objetiva las respuestas generadas por los distintos modelos evaluados y analizar sus principales aciertos y errores.

4.4. Arquitectura general del sistema

Como resultado del desarrollo realizado, el proyecto terminó organizándose en dos líneas de trabajo diferenciadas. Aunque ambas comparten el objetivo de analizar tatuajes mediante técnicas de visión artificial y modelos multimodales, cada una aborda el problema desde una perspectiva distinta.

4.4.1. Primer enfoque: generación de informes forenses


El flujo de trabajo seguido en este enfoque puede resumirse mediante el siguiente esquema:



Las características extraídas constituyen la base de las descripciones generadas posteriormente por el modelo, permitiendo relacionar parte de las observaciones incluidas en el informe con medidas previamente calculadas.

4.4.2. Segundo enfoque: evaluación de modelos multimodales

El segundo enfoque sigue un procedimiento más sencillo orientado a la evaluación de modelos:



Este procedimiento permitió analizar de forma objetiva el comportamiento de distintos modelos visión-lenguaje sobre tareas concretas relacionadas con la identificación de atributos visuales presentes en los tatuajes.

4.4.3. Conjunto de referencia

Para realizar la evaluación fue necesario construir un conjunto de referencia mediante etiquetado manual sobre la partición `test` de Tattoo-YOLO.

Estas anotaciones se utilizaron posteriormente para comparar las respuestas generadas por los distintos modelos y calcular las métricas presentadas en el capítulo de resultados.

4.5. Extractor de características sobre imágenes segmentadas

La primera parte del desarrollo se centró en construir un extractor de características capaz de procesar automáticamente las imágenes de la base HDA Semi-synthetic Tattoo Database.

Este módulo constituye el núcleo del primer enfoque del proyecto y es el encargado de transformar las imágenes y sus máscaras de segmentación en una representación estructurada del tatuaje que posteriormente puede utilizarse durante la generación de informes forenses.

4.5.1. Objetivos del extractor

Durante el diseño del extractor se plantearon tres objetivos principales:

- Procesar automáticamente la totalidad de la base de datos.
- Obtener características interpretables desde un punto de vista forense.
- Generar una representación estructurada que pudiera complementar la información visual utilizada posteriormente por el modelo multimodal.

Para organizar la información extraída se definieron tres grupos principales de características:

- Características espaciales.
- Características geométricas o de forma.
- Características de apariencia visual.

Esta organización permite describir tanto la localización y el tamaño del tatuaje como su forma general y algunas de sus propiedades visuales más relevantes.

4.5.2. Procesamiento inicial de imágenes y máscaras

Cada muestra de la base HDA está compuesta por una imagen RGB y una máscara de segmentación asociada. Ambos elementos se cargan conjuntamente al inicio del proceso y se utilizan durante todas las etapas posteriores de extracción.

Durante las primeras pruebas se observó que algunas máscaras podían almacenarse utilizando varios canales de color. Aunque esta diferencia no afectaba visualmente a la segmentación, sí podía generar inconsistencias durante algunos cálculos. Para evitar este problema, todas las máscaras se transformaron previamente a una representación de un único canal.

Una vez cargadas la imagen y la máscara, se obtienen sus dimensiones y se preparan las estructuras necesarias para calcular las características descritas en las siguientes secciones.

4.5.3. Separación de regiones semánticas

Las máscaras proporcionadas por HDA contienen información sobre tres regiones diferentes: fondo, piel y tatuaje. Sin embargo, para calcular muchas de las características del extractor resultaba más cómodo trabajar con cada una de ellas por separado.

Por este motivo se desarrolló una función encargada de generar automáticamente una máscara binaria independiente para cada región.

```
def mask_to_regions(mask):  
  
    background = (mask <= 30).astype(np.uint8)  
    skin = (mask >= 220).astype(np.uint8)  
    tattoo = ((mask > 30) & (mask < 220)).astype(np.uint8)  
  
    return tattoo, skin, background
```

Algoritmo 4.1: Separación de regiones a partir de la máscara original.

La separación se realiza utilizando umbrales sobre los niveles de intensidad presentes en la máscara original. Como resultado se obtienen tres máscaras binarias independientes correspondientes al fondo, la piel y el tatuaje.




Ilustración 4.3: Separación de las regiones semánticas presentes en la máscara HDA.

La disponibilidad de estas tres regiones permite calcular posteriormente métricas específicas para cada una de ellas, como área relativa, contraste entre piel y tatuaje o características geométricas basadas exclusivamente en la tinta segmentada.

4.5.4. Limpieza de la máscara del tatuaje

Antes de calcular las características finales se realizó una fase de limpieza sobre la región correspondiente al tatuaje.

Aunque las máscaras proporcionadas por HDA presentan una calidad elevada, durante las pruebas iniciales se detectaron pequeñas regiones aisladas que podían afectar negativamente a determinadas métricas geométricas. Para minimizar este problema se aplicó un análisis de componentes conectados que permitió identificar y eliminar regiones de tamaño insignificante.

```
num_labels, labels, stats, centroids = \
cv2.connectedComponentsWithStats(
    tattoo_mask,
    connectivity=8
```

)

Algoritmo 4.2: Detección de componentes conectados.

La eliminación de estas pequeñas regiones permitió obtener contornos más estables y evitar que elementos residuales afectaran al cálculo de las características geométricas descritas en las siguientes secciones.

4.5.5. Características espaciales

Las primeras características calculadas están relacionadas con la distribución espacial del tatuaje dentro de la imagen. Este grupo incluye medidas de tamaño, posición y ocupación relativa de la región tatuada.

4.5.5.1. Medidas de tamaño

Las primeras características obtenidas corresponden al tamaño de la región tatuada.

A partir de la máscara binaria generada durante la fase de preprocesamiento se contabilizaron los píxeles pertenecientes al tatuaje y a la piel visible.

$$A_{tattoo} = \sum TattooMask$$

$$A_{skin} = \sum SkinMask$$

A partir de estas áreas se calcularon dos proporciones complementarias.

La primera expresa la fracción de la imagen ocupada por el tatuaje:

$$TattooFrac = \frac{A_{tattoo}}{A_{image}}$$

La segunda relaciona el área tatuada con la cantidad de piel visible:

$$TattooSkinRatio = \frac{A_{tattoo}}{A_{skin}}$$

Estas proporciones permiten comparar tatuajes entre imágenes con distintas resoluciones y niveles de zoom. Durante las pruebas resultaron más informativas que las áreas absolutas, ya que reducen gran parte de la variabilidad asociada al tamaño de la imagen.

4.5.5.2. Caja envolvente

Para localizar el tatuaje dentro de la imagen se calculó una caja envolvente mínima (*bounding box*) que contiene la totalidad de la región segmentada.

```
x, y, w, h = cv2.boundingRect(
    largest_contour
)
```

Algoritmo 4.3: Obtención de la caja envolvente.

Además de proporcionar una representación sencilla de la localización del tatuaje, la caja envolvente se utilizó posteriormente para generar los recortes enviados al modelo multimodal.




Ilustración 4.4: Ejemplo de caja envolvente calculada a partir de la máscara del tatuaje.

A partir de las dimensiones de la caja también se calculó la relación de aspecto:

$$AspectRatio = \frac{Width}{Height}$$

Esta característica proporciona una primera aproximación a la forma general del tatuaje y complementa las medidas geométricas descritas posteriormente.

4.5.5.3. Posición relativa

También se calculó una estimación de la posición relativa del tatuaje dentro de la imagen.

Para ello se utilizó el centro de la caja envolvente normalizado respecto a las dimensiones de la imagen.

$$x_{norm} = \frac{x_c}{W}$$

$$y_{norm} = \frac{y_c}{H}$$

A partir de estas coordenadas se generó una descripción cualitativa basada en una división de la imagen en una cuadrícula de nueve regiones.

Las posiciones obtenidas se expresan mediante etiquetas como:

- top-left
- top-center
- top-right
- center-left
- center
- center-right
- bottom-left
- bottom-center
- bottom-right

Cabe destacar que estas etiquetas describen únicamente la posición del tatuaje dentro de la imagen y no deben interpretarse como localizaciones anatómicas del cuerpo.

Esta especificación se incorporó posteriormente al diseño de los prompts para evitar que los modelos multimodales realizaran inferencias incorrectas sobre la parte corporal representada.

4.5.6. Características de forma

Además de las características espaciales, se calcularon diversas métricas destinadas a describir la geometría general del tatuaje.

La mayoría de estas características se obtuvieron a partir del contorno principal de la región segmentada.

```

contours, _ = cv2.findContours(
    tattoo_mask,
    cv2.RETR_EXTERNAL,
    cv2.CHAIN_APPROX_SIMPLE
)

contour = max(
    contours,
    key=cv2.contourArea
)

```

Algoritmo 4.4: Obtención del contorno principal.

Este contorno constituye la base para las métricas geométricas descritas a continuación.

4.5.6.1. Compacidad y complejidad geométrica

Las primeras características calculadas fueron el perímetro, la circularidad y la solidez.

El perímetro representa la longitud total del borde externo del tatuaje.

La circularidad mide el grado de semejanza entre la región segmentada y una forma circular ideal.

$$Circularity = \frac{4\pi A}{P^2}$$

donde A representa el área y P el perímetro del contorno.

Valores próximos a uno indican formas compactas y regulares, mientras que valores reducidos suelen corresponder a diseños alargados, fragmentados o con contornos complejos.

La solidez compara el área real del tatuaje con el área de su envolvente convexa (*convex hull*):

$$Solidity = \frac{Area}{HullArea}$$

Esta métrica permite identificar la presencia de concavidades, huecos internos o formas especialmente irregulares.

En conjunto, estas características ofrecen una descripción cuantitativa de la complejidad geométrica del tatuaje y permiten diferenciar diseños compactos de otros más abiertos o fragmentados.

4.5.6.2. Ajuste elíptico y elongación

Para describir la distribución global del tatuaje se ajustó una elipse sobre el contorno principal utilizando las herramientas proporcionadas por OpenCV.

Este ajuste proporciona una aproximación simplificada de la forma general del tatuaje mediante dos ejes principales y una orientación dominante.

A partir de dichos ejes se calculó la elongación:

$$Elongation = \frac{MajorAxis}{MinorAxis}$$

Esta característica permite estimar hasta qué punto la forma del tatuaje presenta una distribución alargada.

Valores próximos a uno indican regiones relativamente compactas, mientras que valores elevados suelen corresponder a diseños claramente longitudinales.

Durante las pruebas esta métrica resultó especialmente útil para transformar información geométrica compleja en descripciones cualitativas fácilmente interpretables por el modelo multimodal.

Por ejemplo, diferentes intervalos de elongación podían traducirse posteriormente en expresiones como:

- not strongly elongated
- moderately elongated
- clearly elongated

4.5.6.3. Orientación

El ajuste elíptico proporciona también una estimación de la orientación dominante de la región tatuada.

Aunque esta característica se conservó dentro de las estructuras de datos generadas por el extractor, finalmente no se incorporó de forma explícita a los informes forenses.

Durante las pruebas se observó que los valores angulares resultaban difíciles de interpretar desde un punto de vista descriptivo y aportaban poca información útil para el objetivo final del sistema. Aun así, se decidió mantener esta métrica por su posible interés en futuros desarrollos o análisis comparativos.




Ilustración 4.5: Características geométricas calculadas sobre la región tatuada.

La Figura 4.5 muestra las principales estructuras geométricas utilizadas durante el análisis. En verde se representa el contorno principal del tatuaje, en azul su envoltorio convexa (*convex hull*) y en rojo la elipse ajustada sobre la región segmentada. Los ejes mayor y menor de la elipse se muestran respectivamente en amarillo y cian.

4.5.7. Características de apariencia

Además de las características espaciales y geométricas, se calculó un conjunto de métricas destinadas a describir la apariencia visual del tatuaje.

Con el objetivo de reducir la influencia de variaciones cromáticas y condiciones de iluminación, la mayoría de estas métricas se calcularon sobre imágenes convertidas previamente a escala de grises.

4.5.7.1. Características de intensidad

Las primeras métricas obtenidas describen la distribución de intensidades presentes tanto en la región tatuada como en la piel circundante.

Para cada región se calculó la intensidad media y la desviación típica de los niveles de gris.

La intensidad media proporciona una estimación de la luminosidad predominante de la región analizada, mientras que la desviación típica describe la variabilidad tonal existente en

su interior.

En general, los tatuajes suelen presentar intensidades inferiores a las de la piel debido a la presencia de tinta oscura. Sin embargo, esta diferencia depende de factores como el color del tatuaje, el tono de piel o las condiciones de iluminación de la imagen.

Estas métricas se utilizaron principalmente como base para calcular características más robustas relacionadas con el contraste entre tatuaje y piel.

4.5.7.2. Contraste entre piel y tatuaje

Una de las características más útiles obtenidas durante esta fase fue el contraste existente entre la región tatuada y la piel visible.

Esta medida se calculó como la diferencia entre las intensidades medias de ambas regiones:

$$Contrast = Mean_{skin} - Mean_{Tattoo}$$

Valores elevados indican una separación visual clara entre la tinta y la piel, mientras que valores bajos suelen corresponder a situaciones donde ambas regiones presentan intensidades similares.

Durante las fases posteriores del proyecto, este valor se transformó en categorías cualitativas utilizadas dentro de los prompts enviados al modelo multimodal.

4.5.7.3. Características del recorte

Además de analizar exclusivamente la región tatuada, se calculó un conjunto de características sobre un recorte centrado en el tatuaje.

Este recorte se obtuvo a partir de la caja envolvente ampliada mediante un pequeño margen adicional, permitiendo conservar parte del contexto visual circundante.




Ilustración 4.6: Proceso de generación del recorte a partir de la región tatuada.

El uso de este recorte permitió incorporar información relacionada con la complejidad visual del entorno inmediato del tatuaje.

4.5.7.4. Complejidad visual

Para estimar la complejidad visual presente en el recorte se utilizaron dos métricas complementarias: densidad de bordes y entropía.

La densidad de bordes se obtuvo mediante el detector de Canny y proporciona una estimación aproximada de la cantidad de estructura visual presente en la imagen. Valores elevados suelen aparecer en tatuajes con numerosos detalles, líneas finas o patrones complejos.

Por otra parte, la entropía mide la diversidad tonal existente en la imagen:

$$Entropy = - \sum p(i) \log_2 p(i)$$

donde $p(i)$ representa la probabilidad asociada a cada nivel de intensidad.

Mientras que la densidad de bordes captura principalmente complejidad estructural, la entropía describe la riqueza tonal de la imagen. La combinación de ambas métricas permitió obtener una estimación razonable de la complejidad visual general del tatuaje.

4.5.7.5. Características descartadas

Durante el desarrollo se experimentó con diversas características adicionales relacionadas principalmente con el color y el estilo visual.

Entre las métricas evaluadas se encontraban:

- Porcentaje de píxeles considerados coloridos.
- Características basadas en saturación.
- Densidad aproximada de tinta.
- Clasificación heurística del estilo visual.

Aunque inicialmente parecían prometedoras, las pruebas realizadas mostraron que estas características eran especialmente sensibles a factores externos como la iluminación, el tono de piel o la propia naturaleza semisintética de algunas imágenes.

Como consecuencia, podían generar resultados inconsistentes o difíciles de justificar objetivamente.

Por este motivo se decidió eliminarlas de la versión final del extractor y mantener únicamente aquellas métricas que mostraban un comportamiento más estable y reproducible.

4.5.8. Estructura final de las características

Una vez calculadas todas las características espaciales, geométricas y de apariencia, fue necesario definir una estructura de almacenamiento que permitiera organizar la información de forma clara y reutilizable.

Tras varias pruebas se optó por utilizar una representación jerárquica en formato JSON. Este formato facilitaba tanto el almacenamiento de las características como su utilización posterior durante la generación de informes.

Las características se organizaron en cuatro bloques principales:

- Información general de la imagen.
- Características espaciales.
- Características de forma.
- Características de apariencia.

La estructura general utilizada puede representarse de forma simplificada mediante el siguiente esquema:

```
features = {  
    "metadata": {...},  
    "spatial_features": {...},  
    "shape_features": {...},  
    "appearance_features": {...}  
}
```

Algoritmo 4.5: Estructura simplificada de las características generadas.

Esta organización permitió mantener separados los distintos tipos de información y simplificó la construcción posterior de los prompts utilizados por el modelo multimodal.

4.5.9. Procesamiento por lotes

Una vez validado el funcionamiento del extractor sobre imágenes individuales, se adaptó el sistema para procesar automáticamente la totalidad de la base de datos HDA.

Dado que el conjunto contiene aproximadamente 5.500 imágenes, el procesamiento se realizó por lotes independientes. Esta estrategia reducía el riesgo de pérdida de resultados ante posibles errores de ejecución y permitía reanudar el procesamiento sin necesidad de comenzar desde cero.

Cada lote generaba automáticamente los ficheros de características correspondientes, almacenados tanto en formato JSON como CSV. Posteriormente, todos los resultados parciales se consolidaron en un único conjunto de datos que contenía las características extraídas para la totalidad de las imágenes procesadas.

Este enfoque ofrecía varias ventajas:

- Reducción del riesgo de pérdida de información.
- Posibilidad de reanudar ejecuciones interrumpidas.
- Validación independiente de los resultados obtenidos.
- Mayor facilidad para depurar errores.

Como resultado final se obtuvieron dos ficheros consolidados que contienen todas las características extraídas:

- `features_all.json`
- `features_all.csv`

Estos ficheros constituyen la salida final del extractor y fueron utilizados posteriormente durante la generación automática de informes forenses.

4.5.10. Resumen del sistema de generación de informes

El sistema desarrollado permitió combinar las características extraídas automáticamente con las capacidades descriptivas de un modelo multimodal para generar informes forenses estructurados.

Los informes generados constituyen el resultado final del primer enfoque del proyecto y sirvieron para estudiar cómo integrar información visual explicable dentro de un proceso de generación automática de descripciones.

4.6. Generación de informes forenses mediante modelos multimodales

Una vez completado el extractor de características, el siguiente paso fue utilizar esa información para generar informes forenses estructurados. Para ello se diseñó un sistema capaz de combinar las características calculadas automáticamente con las capacidades descriptivas de un modelo multimodal.

La idea era que el modelo no trabajara únicamente a partir de la imagen, sino que también recibiera información visual ya analizada durante la fase anterior. De esta forma, parte de las afirmaciones incluidas en el informe podían apoyarse en características objetivas extraídas directamente del tatuaje.

El resultado buscado no era una descripción libre, sino un informe organizado, prudente y centrado únicamente en elementos observables.

4.6.1. Objetivos del sistema de generación

El sistema de generación de informes se diseñó con tres objetivos principales.

En primer lugar, debía producir descripciones coherentes y estructuradas a partir de imágenes de tatuajes. Estas descripciones debían centrarse en aspectos visuales observables, evitando interpretaciones subjetivas o especulaciones sobre el significado del diseño.

En segundo lugar, debía incorporar información procedente del extractor de características para mejorar la explicabilidad de los resultados. Por este motivo, además del recorte visual, el modelo recibía una representación estructurada de las características calculadas previamente.

Por último, se buscó reducir la aparición de alucinaciones. Este aspecto fue especialmente importante durante el desarrollo, ya que los primeros informes generados incluían en ocasiones información no respaldada por la imagen o por las características disponibles.

4.6.2. Selección del modelo multimodal

Durante las primeras fases del proyecto se probaron distintos modelos visión-lenguaje para analizar su capacidad de generar descripciones detalladas de tatuajes.

Las primeras pruebas se realizaron con Moondream2. Este modelo tenía la ventaja de ser ligero, rápido y sencillo de ejecutar en Google Colab, por lo que inicialmente parecía una opción adecuada para comenzar los experimentos.

Sin embargo, los resultados obtenidos mostraron varias limitaciones. Aunque Moondream2 respondía correctamente a preguntas sencillas, sus descripciones eran generalmente breves, poco estructuradas y con un nivel de detalle insuficiente para el tipo de informe que se quería generar.

Además, el modelo tenía dificultades para combinar la información visual de la imagen con las características estructuradas proporcionadas como contexto adicional. Por este motivo se decidió probar modelos más avanzados de la familia Qwen-VL.

Finalmente se seleccionó Qwen2.5-VL como modelo principal para la generación de informes forenses. La elección se basó principalmente en tres aspectos:

- Mayor capacidad para seguir instrucciones complejas.
- Generación de textos más largos y estructurados.
- Mejor integración de información visual y textual.

Estas características eran importantes porque el modelo debía producir informes organizados en varias secciones y respetar restricciones específicas relacionadas con el contexto forense.

Las pruebas realizadas mostraron que Qwen2.5-VL generaba descripciones más consistentes y detalladas que Moondream2. También respondía mejor a las restricciones incorporadas en los prompts, por lo que se adoptó como modelo definitivo para la generación de informes.

4.6.3. Preparación de la entrada

Una vez seleccionado el modelo multimodal, fue necesario definir qué información recibiría como entrada.

A diferencia de un enfoque basado únicamente en la imagen completa, el sistema desarrollado utiliza dos fuentes de información complementarias.

Por una parte, el modelo recibe un recorte visual centrado en la región tatuada. Este recorte se genera automáticamente a partir de la caja envolvente calculada durante la fase de extracción de características y permite centrar la atención del modelo en la zona de interés.

Por otra parte, el modelo recibe una descripción estructurada derivada de las características espaciales, geométricas y de apariencia obtenidas previamente.

Esta combinación permite proporcionar simultáneamente evidencia visual directa e información cuantitativa ya procesada.

El flujo general seguido por el sistema puede resumirse de la siguiente forma:

Imagen+Máscara $\rightarrow$ *Características* $\rightarrow$ *Interpretación cualitativa* $\rightarrow$ *Prompt* $\rightarrow$ *Qwen2,5-VL* $\rightarrow$ *Info*

De esta manera, el modelo no trabaja exclusivamente sobre la imagen, sino que dispone también de información obtenida mediante técnicas de visión artificial. Este aspecto constituye una de las principales diferencias respecto a un enfoque puramente generativo y permite respaldar parte de las descripciones generadas mediante características calculadas de forma objetiva.

4.6.4. Transformación de características cuantitativas

Uno de los principales retos encontrados durante el desarrollo fue decidir cómo integrar las características extraídas dentro del proceso de generación de informes.

Aunque el extractor produce un conjunto amplio de métricas numéricas, utilizar directamente estos valores como entrada para el modelo presentaba varios inconvenientes. Muchos de ellos carecen de significado intuitivo para un lector humano y resultan difíciles de incorporar de forma natural dentro de una descripción textual.

Por ejemplo, conocer el valor exacto de la circularidad o de la elongación aporta poca información si no se proporciona algún tipo de interpretación adicional. Además, incluir una gran cantidad de valores numéricos dentro del prompt aumentaba su complejidad y dificultaba la generación de textos fluidos.

Por este motivo se optó por una estrategia intermedia. En lugar de proporcionar directamente los valores calculados, se desarrolló un conjunto de reglas encargado de transformar cada característica en una descripción cualitativa más fácil de interpretar.

Esta decisión permitía conservar la información obtenida por el extractor y, al mismo tiempo, facilitar su incorporación dentro del informe generado por el modelo.

Por ejemplo, características como la elongación, el contraste o la complejidad visual se transformaban en categorías descriptivas como:

- not strongly elongated
- moderately elongated
- clearly elongated
- low contrast
- moderate contrast
- strong contrast

El mismo procedimiento se aplicó a otras características como:

- tamaño relativo
- compacidad
- complejidad visual
- variabilidad tonal
- presencia de estructuras alargadas

De esta forma, el modelo recibía una representación semántica de las características en lugar de una lista de valores numéricos difíciles de interpretar.

Esta transformación constituyó el enlace entre el extractor y el modelo multimodal, permitiendo combinar información cuantitativa y generación de lenguaje natural de una forma más coherente e interpretable.

4.6.5. Refinamiento del prompt y control de alucinaciones

El diseño del prompt fue uno de los aspectos que más evolucionó a lo largo del proyecto. Aunque inicialmente se esperaba que las características extraídas ayudaran a guiar la generación de los informes, las primeras pruebas mostraron que las instrucciones proporcionadas al modelo tenían un impacto igual o incluso mayor sobre la calidad del resultado final.

Por este motivo, una parte importante del desarrollo se centró en experimentar con distintas versiones del prompt y analizar cómo afectaban al comportamiento del modelo. A medida que aparecían nuevos errores o respuestas poco deseables, las instrucciones se modificaban para intentar corregirlos.

Las primeras versiones utilizaban instrucciones relativamente simples que incluían el recorte visual del tatuaje junto con una descripción resumida de las características extraídas. Aunque los resultados eran razonablemente coherentes, comenzaron a aparecer diversos comportamientos problemáticos.

Entre los errores detectados con mayor frecuencia se encontraban:

- Inferencias sobre la localización anatómica del tatuaje.
- Atribución de significados simbólicos o culturales.
- Descripciones excesivamente subjetivas.
- Afirmaciones no respaldadas por la evidencia visual disponible.
- Tendencia a exagerar la utilidad identificativa del tatuaje.

Estos problemas aparecían incluso cuando la imagen no contenía suficiente información para justificar ese tipo de conclusiones. En algunos casos el modelo identificaba automáticamente brazos, piernas o torso a partir de recortes muy reducidos. En otros atribuía signifi-

cados culturales, religiosos o emocionales a diseños que únicamente podían describirse desde un punto de vista visual.

Después de observar estos errores de forma repetida, se decidió limitar explícitamente el margen de interpretación del modelo. En lugar de proporcionar únicamente instrucciones generales, se fueron incorporando restricciones específicas orientadas a corregir los problemas detectados durante las pruebas.

Otro aspecto que fue cambiando durante el desarrollo fue la forma de incorporar las características extraídas al prompt. En las primeras versiones se experimentó con la inclusión directa de algunas métricas numéricas, pero no resultaba lógico añadir valores numéricos en un informe forense. Como se explicó en la sección anterior, finalmente se optó por transformar estas métricas en descripciones cualitativas más fáciles de interpretar. De esta forma, el modelo recibía expresiones como *moderately elongated*, *strong contrast* o *high contour activity* en lugar de valores numéricos aislados.

Especial atención recibió el problema de las inferencias anatómicas. Durante las primeras pruebas se comprobó que el modelo tendía a identificar automáticamente partes del cuerpo aunque únicamente dispusiera de un recorte centrado sobre el tatuaje. Dado que la información disponible no permitía determinar con fiabilidad la localización anatómica, se añadieron instrucciones explícitas para impedir este tipo de interpretaciones.

De forma similar, también se incorporaron restricciones destinadas a evitar la atribución de significados culturales, religiosos, emocionales o personales a los diseños observados.

Un fragmento representativo de las restricciones incluidas en la versión final del prompt puede verse a continuación:

VERY IMPORTANT:

- * Never infer anatomical body location.
- * Describe only visible visual properties.
- * Do not speculate about meaning or symbolism.
- * Do not infer identity or personal history.
- * Do not mention raw numeric values.
- * Be conservative and evidence-based.

Algoritmo 4.6: Restricciones incorporadas al prompt final.

No todas estas restricciones estuvieron presentes desde el inicio. Muchas surgieron directamente como respuesta a errores observados durante las pruebas. Cada nueva versión del prompt se evaluaba sobre diferentes imágenes y, cuando aparecía un comportamiento problemático de forma recurrente, se añadían instrucciones específicas para intentar corregirlo.

A lo largo del desarrollo se realizaron múltiples ajustes de este tipo hasta alcanzar una versión del prompt suficientemente estable para generar informes sobre conjuntos completos de imágenes.

La versión final quedó organizada en varios bloques claramente diferenciados:

1. Definición del rol del sistema.

2. Restricciones forenses y criterios de interpretación.
3. Características cualitativas derivadas del extractor.
4. Imagen recortada del tatuaje.
5. Estructura requerida para el informe final.

Esta organización permitió reducir significativamente la aparición de información inventada y favoreció la generación de informes más prudentes, coherentes y alineados con los objetivos del proyecto.

Además, se incorporó explícitamente una sección dedicada a incertidumbres y limitaciones. Durante las primeras pruebas se observó que el modelo tendía a presentar todas sus afirmaciones con un elevado nivel de confianza, incluso cuando la evidencia visual era insuficiente. La inclusión de este apartado ayudó a generar informes más realistas y a reflejar mejor los límites de la información disponible en cada imagen.

4.6.6. Estructura del informe generado

Además del contenido del prompt, otro aspecto que fue cambiando durante las pruebas fue la forma en que se organizaba la respuesta generada por el modelo.

Las primeras versiones permitían respuestas relativamente libres. Aunque esto ofrecía cierta flexibilidad, los resultados eran bastante irregulares. Algunos informes resultaban demasiado breves, otros se centraban en detalles poco relevantes y, en ocasiones, la información aparecía organizada de forma diferente entre unas imágenes y otras.

Para mejorar la consistencia de los resultados se decidió definir una estructura fija que guiara al modelo y le obligara a cubrir siempre los mismos aspectos del análisis. Esto también facilitaba la comparación entre informes y permitía evaluar mejor el efecto de los cambios introducidos en el prompt.

La estructura del informe fue evolucionando al mismo tiempo que lo hacía el propio prompt. Las primeras versiones se centraban principalmente en describir los elementos visibles del tatuaje y comentar su posible interés desde un punto de vista forense. Posteriormente se fueron incorporando nuevas secciones para separar de forma más clara la descripción visual, la interpretación apoyada en características extraídas automáticamente y las limitaciones del análisis.

Otro cambio importante fue la incorporación progresiva de la información generada por el extractor de características. En las primeras pruebas el modelo trabajaba principalmente a partir del recorte de la imagen. Más adelante comenzaron a añadirse descripciones derivadas de las características espaciales, geométricas y de apariencia, permitiendo complementar la observación visual con información obtenida automáticamente durante el procesamiento previo. Como consecuencia, aparecieron apartados específicos destinados a relacionar estas características con la descripción generada por el modelo.

Tras varias iteraciones se llegó a una estructura formada por cinco secciones principales:

- **Observed Description:** descripción objetiva de los elementos visibles en el tatuaje, evitando interpretaciones sobre su significado o contexto.
- **Feature-Based Interpretation:** interpretación apoyada en las características extraídas automáticamente por el sistema.
- **Visual Assessment:** valoración general de la apariencia visual del tatuaje, incluyendo aspectos como complejidad, contraste o nivel de detalle.
- **Forensic Relevance:** descripción prudente de aquellos elementos que podrían resultar útiles para tareas de comparación o identificación visual.
- **Limitations and Uncertainty:** apartado dedicado a recoger las principales limitaciones del análisis y aquellos aspectos que no pueden determinarse con suficiente fiabilidad.

La incorporación de una sección sobre limitaciones e incertidumbres permitió detectar qué cuestiones no podían determinarse con seguridad a partir de la información disponible.

En general, la utilización de una estructura fija ayudó a obtener informes más consistentes y facilitó tanto la revisión de los resultados como la comparación entre diferentes pruebas realizadas durante el desarrollo.

4.6.7. Generación automática por lotes

Una vez validado el funcionamiento del sistema sobre imágenes individuales, el proceso se adaptó para generar informes automáticamente sobre conjuntos completos de imágenes.

Dado que la generación mediante modelos multimodales supone un coste computacional considerable, especialmente cuando se trabaja con miles de muestras, se optó por procesar las imágenes de forma secuencial y almacenar periódicamente los resultados obtenidos.

Para cada imagen se ejecutaban las siguientes etapas:

1. Carga de las características previamente extraídas.
2. Obtención del recorte visual asociado al tatuaje.
3. Construcción automática del prompt.
4. Generación del informe mediante Qwen2.5-VL.
5. Almacenamiento del resultado generado.

Los informes se almacenaron en formato JSON siguiendo una estructura homogénea para todas las imágenes procesadas. Esto facilitó tanto la revisión posterior de los resultados como la reutilización de los informes durante distintas fases del proyecto.

Además, el procesamiento por lotes permitía recuperar fácilmente ejecuciones interrumpidas y supervisar progresivamente el comportamiento del modelo sin necesidad de repetir el proceso completo.

4.6.8. Limitaciones detectadas

A pesar de los resultados obtenidos, durante el desarrollo del sistema se identificaron diversas limitaciones que conviene tener en cuenta a la hora de interpretar los informes generados.

La primera está relacionada con la propia naturaleza de los modelos multimodales. Aunque Qwen2.5-VL mostró un comportamiento más consistente que otros modelos evaluados, sigue siendo susceptible de generar afirmaciones incorrectas o insuficientemente justificadas a partir de la información disponible. Precisamente por este motivo se incorporaron múltiples restricciones dentro de los prompts, aunque el riesgo de generar interpretaciones erróneas no puede eliminarse completamente.

Otra limitación deriva de las propias imágenes analizadas. Factores como la iluminación, el contraste, la resolución o la visibilidad parcial del tatuaje pueden afectar tanto a la extracción de características como a la interpretación realizada posteriormente por el modelo.

También debe tenerse en cuenta que la base HDA utilizada durante esta fase está formada por imágenes semisintéticas. Aunque resultó adecuada para desarrollar y validar el extractor de características, no representa toda la variabilidad presente en imágenes reales obtenidas en contextos operativos o forenses.

Por otra parte, las características calculadas por el extractor describen principalmente propiedades geométricas y visuales generales. Aspectos más complejos relacionados con el contenido semántico del tatuaje, su posible significado o determinados detalles artísticos quedan fuera del alcance de las métricas utilizadas.

Finalmente, el sistema desarrollado debe entenderse como una herramienta de apoyo al análisis forense y no como un sustituto del criterio de un especialista. Los informes generados pueden facilitar la descripción y documentación de tatuajes, pero cualquier interpretación final debe realizarse teniendo en cuenta el contexto completo de la investigación.

4.6.9. Resumen del sistema de generación de informes

El sistema desarrollado permitió combinar las características extraídas automáticamente con las capacidades descriptivas de un modelo multimodal para generar informes forenses estructurados.

Los informes generados constituyen el resultado final del primer enfoque del proyecto y sirvieron para estudiar cómo integrar información visual explicable dentro de un proceso de generación automática de descripciones.

4.7. Evaluación de modelos multimodales sobre imágenes no segmentadas

Una vez completado el sistema de generación de informes sobre la base de datos HDA, se decidió estudiar el comportamiento de distintos modelos multimodales sobre la base de datos Tattoo-YOLO.

La idea inicial consistía en reutilizar el extractor de características desarrollado durante la primera parte del proyecto y adaptarlo a las imágenes de este nuevo conjunto de datos. Aunque las anotaciones disponibles no proporcionaban máscaras de segmentación, sí incluían cajas delimitadoras (*bounding boxes*) que indicaban la localización aproximada del tatuaje dentro de la imagen.

A partir de estas anotaciones se exploraron distintas estrategias con el objetivo de obtener una representación suficientemente precisa de la región tatuada y poder reutilizar posteriormente las características desarrolladas para HDA. Entre las aproximaciones evaluadas se encontraban la umbralización en escala de grises, el análisis de intensidad, la segmentación basada en color y la detección aproximada de regiones de piel.

Sin embargo, tras realizar diversas pruebas se comprobó que estas técnicas no ofrecían resultados suficientemente fiables. El principal problema era que las anotaciones YOLO únicamente proporcionan una localización aproximada del tatuaje. Dentro de una misma caja delimitadora podían aparecer regiones de piel, ropa, cabello, sombras o elementos del fondo que interferían directamente con el proceso de segmentación.

Como consecuencia, muchas de las características utilizadas en el primer enfoque dejaban de ser fiables. Métricas como el contraste piel-tatuaje, el área exacta de tinta, la circularidad o la solidez requieren conocer con precisión qué píxeles pertenecen realmente al tatuaje, información que no estaba disponible en esta base de datos.

Además, se observó que algunos errores de segmentación producían valores aparentemente razonables aunque no representasen correctamente el tatuaje presente en la imagen, dificultando su detección automática durante el proceso de validación.

Ante estas limitaciones se decidió replantear la segunda parte del trabajo. En lugar de intentar reconstruir artificialmente una segmentación inexistente, se optó por aprovechar directamente las capacidades de los modelos multimodales para analizar imágenes y responder preguntas sobre su contenido.

Este cambio simplificó considerablemente el problema y permitió trabajar directamente sobre las imágenes originales. Como consecuencia, el objetivo pasó de ser la extracción automática de características a la evaluación de capacidades visuales específicas de distintos modelos visión-lenguaje.

El nuevo enfoque consistió en formular preguntas controladas sobre cada imagen y comparar posteriormente las respuestas generadas por los modelos con un conjunto de etiquetas manuales. De esta forma fue posible realizar una evaluación cuantitativa y comparar de manera objetiva el comportamiento de diferentes arquitecturas multimodales.

4.7.1. Selección de las variables evaluadas

Una vez definido el nuevo enfoque, fue necesario decidir qué aspectos visuales se iban a evaluar.

Se buscó un conjunto de variables que pudieran identificarse directamente a partir de la imagen y que, al mismo tiempo, resultaran relevantes para el análisis de tatuajes. Además, era importante que pudieran etiquetarse de forma relativamente consistente para construir posteriormente un conjunto de referencia fiable.

Tras varias pruebas se seleccionaron cinco variables relacionadas con la presencia de tatuajes, su tamaño aproximado, la existencia de color, la presencia de texto y el número de tatuajes visibles.

La Tabla 4.2 resume las variables finalmente utilizadas durante la evaluación.

Cuadro 4.2: Variables evaluadas en la segunda parte del proyecto.

Variable	Descripción	Etiquetas
has_tattoo	Indica si existe un tatuaje visible	yes / no
tattoo_size	Tamaño aproximado del tatuaje	small / medium / large
tattoo_color	Presencia de color en la tinta	black_and_gray / colored
contains_text	Presencia de letras o números	yes / no
tattoo_count	Número de tatuajes visibles	single / multiple

4.7.2. Construcción del conjunto de referencia

Una vez definidas las variables, fue necesario crear un conjunto de referencia que permitiera comparar objetivamente las respuestas generadas por los distintos modelos.

Las anotaciones originales de Tattoo-YOLO únicamente proporcionan información sobre la localización aproximada de los tatuajes dentro de la imagen, por lo que no podían utilizarse para evaluar variables como tamaño, color, presencia de texto o número de tatuajes visibles.

Por este motivo se realizó un proceso de etiquetado manual sobre la partición **test** de la base de datos, formada por aproximadamente 450 imágenes. Este tamaño resultó suficientemente grande para obtener resultados representativos y, al mismo tiempo, manejable para realizar una revisión manual completa.

4.7.3. Proceso y criterios de etiquetado

El etiquetado se realizó mediante inspección visual de todas las imágenes pertenecientes a la partición **test**.

Para cada imagen se asignaron etiquetas correspondientes a las cinco variables definidas previamente.

La variable `has_tattoo` se consideró positiva cuando existía al menos un tatuaje claramente visible en la imagen. La variable `tattoo_size` se clasificó en las categorías `small`, `medium` y `large` según la proporción aproximada ocupada por el tatuaje respecto a la región corporal visible.

La variable `tattoo_color` permitió distinguir entre tatuajes monocromáticos y tatuajes con presencia significativa de color. Por su parte, `contains_text` identificaba la presencia de letras, palabras o números reconocibles, mientras que `tattoo_count` diferenciaba entre imágenes con un único tatuaje visible y aquellas donde aparecían múltiples tatuajes.

Los mismos criterios se mantuvieron durante todo el proceso con el objetivo de garantizar la mayor consistencia posible entre las anotaciones realizadas.

4.7.4. Almacenamiento de las etiquetas

Las etiquetas obtenidas se almacenaron en un fichero tabular que posteriormente se utilizó como referencia durante la evaluación de los modelos.

La estructura utilizada fue la siguiente:

```
filename ,  
has_tattoo ,  
tattoo_size ,  
tattoo_color ,  
contains_text ,  
tattoo_count
```

Algoritmo 4.7: Estructura simplificada del conjunto de referencia.

Cada fila representa una imagen del conjunto de test y contiene las etiquetas manuales asociadas.

Este fichero constituye el *ground truth* utilizado posteriormente para calcular las métricas de evaluación de los distintos modelos multimodales.

4.7.5. Importancia del conjunto de referencia

Las etiquetas manuales obtenidas durante este proceso sirvieron como referencia para evaluar de forma objetiva las respuestas generadas por los distintos modelos multimodales.

Gracias a ello, fue posible comparar sus resultados utilizando las mismas imágenes y los mismos criterios de evaluación en todos los experimentos realizados.

4.7.6. Modelos evaluados

Para realizar la evaluación se seleccionaron tres modelos multimodales con características diferentes.

Los modelos utilizados fueron:

- Moondream2
- LLaVA 1.5 7B
- Qwen2-VL 2B Instruct

La selección buscaba incluir modelos de distintos tamaños y arquitecturas, todos ellos accesibles dentro del entorno de trabajo utilizado durante el proyecto.

La Tabla 4.3 resume sus principales características.

Cuadro 4.3: Modelos multimodales evaluados.

Modelo	Tamaño	Uso dentro del proyecto
Moondream2	Ligero	Primer modelo utilizado durante las pruebas multimodales.
LLaVA 1.5 7B	7B parámetros	Modelo de referencia ampliamente utilizado en tareas visión-lenguaje.
Qwen2-VL 2B Instruct	2B parámetros	Modelo empleado en la evaluación comparativa final.

El objetivo no era analizar qué modelo generaba respuestas más elaboradas, sino comparar su capacidad para identificar correctamente las distintas características visuales evaluadas.

4.7.7. Diseño de las preguntas

Una vez definidas las variables que iban a evaluarse, fue necesario transformarlas en preguntas que pudieran ser respondidas directamente por los modelos multimodales.

Para cada variable se diseñó una pregunta independiente con el objetivo de obtener respuestas breves y fácilmente comparables con las etiquetas manuales. De esta forma, cada consulta se centraba en un único aspecto visual de la imagen, lo que permitía analizar por separado el comportamiento de los modelos en cada una de las tareas planteadas.

Además, las instrucciones se formularon de manera explícita para intentar reducir la variabilidad de las respuestas. En aquellos casos donde las variables disponían de un conjunto cerrado de categorías, las propias opciones válidas se incluían dentro de la pregunta.

Un ejemplo simplificado de las preguntas utilizadas puede observarse a continuación.

```

QUESTIONS = {

    "has_tattoo":
        "Is there a visible tattoo in the image?
        Answer only yes or no.",

    "tattoo_size":
        "Classify the tattoo size as
        small, medium or large.",

    "tattoo_color":
        "Is the tattoo black and gray
        or colored?",

    "contains_text":
        "Does the tattoo contain visible
        text? Answer yes or no.",

    "tattoo_count":
        "Is there a single tattoo or
        multiple tattoos visible?"
}

```

Algoritmo 4.8: Ejemplo de preguntas utilizadas durante la evaluación.

Aunque las preguntas eran relativamente sencillas, permitían evaluar capacidades diferentes relacionadas con la detección de tatuajes, la estimación de su tamaño, la identificación de color, la presencia de texto y el número de tatuajes visibles en la imagen.

Este planteamiento resultó más adecuado para los objetivos de esta fase que la generación de descripciones libres, ya que facilitaba posteriormente la comparación entre modelos y el cálculo de métricas de evaluación.

4.7.8. Exploración mediante preguntas abiertas

Aunque la evaluación principal se basó en preguntas categóricas, una vez completada la comparación cuantitativa se realizaron pruebas adicionales utilizando preguntas abiertas sobre un subconjunto de imágenes.

Estas pruebas se llevaron a cabo exclusivamente con Qwen2-VL, ya que fue el modelo que obtuvo los mejores resultados durante la evaluación basada en clasificación.

El objetivo de esta fase no era calcular métricas de rendimiento, sino explorar capacidades que resultan difíciles de evaluar mediante etiquetas cerradas. En particular, se analizó la capacidad del modelo para generar descripciones más elaboradas, identificar elementos visuales relevantes y producir respuestas con un mayor nivel de detalle.

A diferencia de las preguntas categóricas utilizadas durante la evaluación principal, estas instrucciones permitían respuestas libres y requerían interpretar simultáneamente múltiples aspectos de la imagen.

Los resultados obtenidos se analizan posteriormente en el capítulo de resultados desde una perspectiva cualitativa.

4.7.9. Pipeline de evaluación

Una vez definidas las preguntas, se implementó un procedimiento común para todos los modelos evaluados.

Para cada imagen del conjunto de test se repetía exactamente la misma secuencia de pasos:

1. Carga de la imagen.
2. Selección de la pregunta correspondiente.
3. Envío de la imagen y la pregunta al modelo.
4. Generación de la respuesta.
5. Normalización de la salida.
6. Comparación con la etiqueta manual.

Este proceso se ejecutó para todas las combinaciones imagen-pregunta-modelo, generando un conjunto completo de predicciones que posteriormente se utilizó para calcular las métricas de evaluación.

4.7.10. Normalización de respuestas

Con el objetivo de facilitar la comparación con las etiquetas manuales, las respuestas generadas por los modelos se transformaron a un conjunto común de categorías.

Para cada variable evaluada se definieron reglas de conversión específicas que permitían obtener una etiqueta final directamente comparable con el conjunto de referencia.

Esta etapa garantizaba que todas las predicciones se almacenaran siguiendo el mismo formato antes de calcular las métricas de evaluación.

4.7.11. Almacenamiento de resultados

Todas las predicciones obtenidas durante la evaluación se almacenaron en ficheros estructurados para facilitar su análisis posterior.

Cada registro incluía la imagen evaluada, la variable analizada, la etiqueta de referencia, la predicción generada y el modelo utilizado.

Esta organización permitió calcular posteriormente las métricas de rendimiento para cada variable y cada modelo por separado, además de facilitar la revisión de errores y el análisis de casos concretos.

4.7.12. Resumen del proceso de evaluación

El procedimiento descrito permitió comparar distintos modelos multimodales utilizando las mismas imágenes, las mismas preguntas y el mismo conjunto de referencia.

Las predicciones obtenidas durante esta fase constituyen la base de los resultados experimentales presentados en el capítulo siguiente.

4.8. Consideraciones finales sobre el desarrollo

El desarrollo del proyecto no siguió un proceso completamente lineal. Aunque los objetivos generales se mantuvieron desde el inicio, varias decisiones técnicas tuvieron que revisarse a medida que avanzaba el trabajo y se obtenían nuevos resultados experimentales.

Algunas características inicialmente consideradas prometedoras fueron descartadas por falta de robustez, los modelos multimodales utilizados evolucionaron durante las distintas fases del proyecto y parte de la metodología prevista para la base Tattoo-YOLO tuvo que replantearse debido a las limitaciones de las anotaciones disponibles.

Lejos de suponer un inconveniente, estos ajustes permitieron adaptar progresivamente el sistema a las características reales de los datos y a las capacidades observadas en los modelos evaluados. El resultado final es una solución que combina extracción de características explicables, generación de informes forenses y evaluación experimental de modelos multimodales sobre imágenes reales.

Una vez completado el desarrollo de los distintos componentes del sistema, el siguiente capítulo presenta los resultados obtenidos y el análisis experimental realizado sobre los modelos evaluados.

Capítulo 5

Resultados

5.1. Resultados del extractor de características

La ejecución del extractor sobre la base de datos HDA permitió obtener automáticamente una representación estructurada de cada tatuaje a partir de las máscaras de segmentación disponibles.

Para cada imagen se calcularon características relacionadas con:

- Posición relativa del tatuaje dentro de la imagen.
- Tamaño y proporción ocupada por la región tatuada.
- Corma geométrica general.
- Complejidad visual.
- Contraste respecto a la piel.
- Cistribución espacial de la tinta.
- Características derivadas del recorte visual.

Uno de los principales objetivos de esta fase consistía en garantizar que las características obtenidas fueran interpretables y suficientemente robustas para su utilización posterior en la generación de informes. Durante el desarrollo se exploraron métricas adicionales relacionadas con color, saturación y estilo visual. Sin embargo, las pruebas realizadas mostraron que algunas de ellas resultaban especialmente sensibles a factores como la iluminación o las particularidades de las imágenes utilizadas, por lo que finalmente se optó por conservar únicamente aquellas características que ofrecían un comportamiento más consistente y fácilmente justificable desde el punto de vista visual.

Como resultado, el extractor produjo una representación estructurada basada en propiedades espaciales, geométricas y de apariencia que podían relacionarse directamente con elementos observables en la imagen.

La Figura 5.1 muestra un ejemplo representativo del funcionamiento del extractor sobre una imagen de la base HDA.

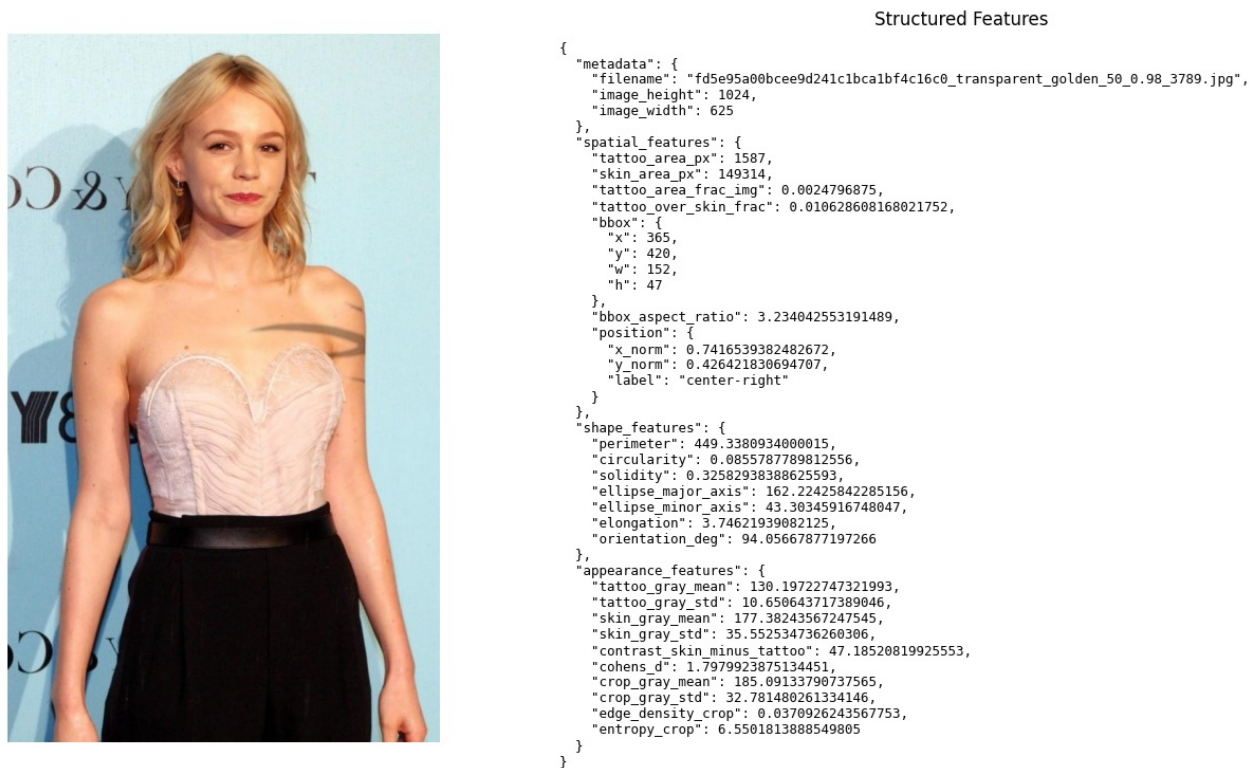


Ilustración 5.1: Ejemplo de salida generada por el extractor de características.

A partir de la máscara de segmentación, el sistema es capaz de identificar con precisión la región correspondiente al tatuaje y calcular automáticamente todas las características definidas durante la fase de desarrollo.

Además de facilitar la generación posterior de informes, las características obtenidas permiten describir objetivamente numerosos aspectos visuales de los tatuajes sin necesidad de realizar interpretaciones subjetivas. Esta propiedad constituye uno de los elementos centrales del enfoque propuesto, ya que proporciona un nivel adicional de explicabilidad respecto a sistemas basados exclusivamente en modelos multimodales.

La Tabla 5.1 resume los principales grupos de características generados por el extractor.

Cuadro 5.1: Grupos de características obtenidos por el extractor.

Grupo	Información proporcionada
Espaciales	Posición y distribución dentro de la imagen.
Geométricas	Área, perímetro, elongación y circularidad.
Apariencia	Contraste, complejidad visual y tonalidad.
Recorte	Información derivada de la región utilizada por el modelo.
Metadatos	Identificación y parámetros de procesamiento.

Los resultados también muestran que no siempre es algo positivo incorporar un número elevado de características. Durante las distintas pruebas se observó que un conjunto más reducido de métricas, seleccionadas con detalle por su estabilidad e interpretabilidad, proporcionaba una representación más útil para las fases posteriores del sistema que una descripción excesivamente detallada basada en características difíciles de justificar.

En general, los resultados indican que el uso de máscaras de segmentación permite calcular características visuales de forma consistente y reproducible. Cabe tener en cuenta que la calidad de las métricas obtenidas depende directamente de la precisión de las segmentaciones disponibles, por lo que la fiabilidad del extractor está ligada a la calidad de las anotaciones utilizadas como entrada.

5.2. Resultados de generación de informes forenses

Tras completar la extracción de características, se evaluó la capacidad del sistema para generar informes forenses a partir de la combinación de información visual y características explicables obtenidas automáticamente.

En esta parte se observa que esta combinación permite generar descripciones estructuradas y generalmente coherentes con el contenido visual de las imágenes analizadas. Además, el proceso de refinamiento de prompts ayudó a reducir de forma significativa la aparición de inferencias injustificadas, especialmente aquellas relacionadas con la localización anatómica, el significado simbólico de los tatuajes o posibles interpretaciones personales.

5.2.1. Calidad general de los informes

De forma general, los informes generados mantuvieron correctamente la estructura definida durante la fase de diseño.

Las distintas secciones permitieron separar observaciones visuales directas, información derivada de las características extraídas automáticamente y limitaciones asociadas al análisis realizado. Esta organización facilitó la interpretación de los resultados y mejoró la trazabilidad de las descripciones generadas.

Se observó además una elevada coherencia entre la información proporcionada por el extractor y los textos generados por el modelo multimodal. Características como el tamaño relativo, la elongación, el contraste o la complejidad visual tendían a reflejarse de forma consistente dentro de los informes.

Otro aspecto relevante fue la capacidad del sistema para reconocer explícitamente ciertas incertidumbres cuando la información disponible no permitía realizar afirmaciones concluyentes. Este comportamiento resulta especialmente valioso en un contexto forense, donde la prudencia y la correcta delimitación de la evidencia disponible constituyen factores fundamentales.

5.2.2. Ejemplo de informe generado

La Figura 5.2 muestra un ejemplo de imagen utilizada por el sistema para la generación automática de informes.



Ilustración 5.2: Ejemplo de tatuaje utilizado para la generación automática del informe.

Observed Description

The tattoo depicts a stylized dragon with a fierce expression. The body is elongated and curved, with detailed scales and a long tail. The overall composition is vertical and line-based, with the dragon's head positioned in the upper region of the design.

Feature-Based Interpretation

The tattoo is relatively small and occupies a central portion of the visible skin area. Its geometry is vertically elongated and moderately curved. The contour is well-defined and the contrast against the surrounding skin is moderate.

Visual Assessment

The tattoo presents a clean line-based structure with no evident shading or filling. The composition appears coherent and visually organized, with sharp contours and a clear silhouette.

Forensic Relevance

The distinctive dragon design, together with its geometric characteristics and position, may contribute as a soft biometric cue during forensic comparison.

Limitations and Uncertainty

Conclusions are based solely on the visible image and extracted features. Visibility conditions, image quality and crop selection may affect the interpretation of the tattoo.

En este ejemplo puede observarse cómo el modelo combina la evidencia visual disponible con las características calculadas previamente para construir una descripción estructurada del tatuaje.

La organización del informe facilita distinguir qué observaciones proceden directamente de la imagen y cuáles se apoyan en información derivada del extractor de características.

5.2.3. Análisis cualitativo

La revisión manual de los informes generados permitió identificar varios aspectos positivos del enfoque desarrollado.

En primer lugar, las descripciones obtenidas resultaron generalmente coherentes con el contenido visual de las imágenes analizadas. El sistema fue capaz de describir adecuadamente propiedades relacionadas con la forma general, el contraste, la complejidad visual y la distribución espacial de los tatuajes.

En segundo lugar, la utilización de características explicables proporcionó una capa adicional de interpretabilidad respecto a enfoques basados exclusivamente en modelos multimodales. Esto permite relacionar parte de las afirmaciones presentes en los informes con medidas calculadas objetivamente a partir de la segmentación disponible.

Finalmente, la estructura fija de los informes contribuyó a mantener una mayor consistencia entre distintas ejecuciones y facilitó la comparación de resultados.

5.2.4. Limitaciones observadas

A pesar de los resultados obtenidos, durante el análisis también se identificaron diversas limitaciones.

La calidad final del informe depende en gran medida de la precisión de las características extraídas y de la calidad visual de la imagen analizada. Segmentaciones incorrectas o imágenes con escaso contraste pueden afectar directamente al contenido generado.

Además, aunque las restricciones incorporadas en los prompts redujeron considerablemente la aparición de alucinaciones, no eliminaron por completo este problema. En algunos tatuajes especialmente complejos, abstractos o visualmente ambiguos continuaron apareciendo interpretaciones parcialmente incorrectas, inventadas o afirmaciones insuficientemente respaldadas por la evidencia disponible.

Por último, el sistema continúa dependiendo de modelos multimodales de gran tamaño, lo que implica tiempos de procesamiento relativamente elevados cuando se trabaja con conjuntos de datos extensos. Este aspecto constituye una de las principales líneas de mejora para futuros desarrollos.

5.3. Resultados de evaluación multimodal

La Tabla 5.2 resume la precisión obtenida por los tres modelos multimodales evaluados para cada una de las variables analizadas.

Cuadro 5.2: Precisión obtenida por cada modelo multimodal.

Variable	Moondream2	LLaVA 1.5 7B	Qwen2-VL 2B
has_tattoo	97.96	100.00	99.77
tattoo_size	55.43	39.82	61.76
tattoo_color	72.40	72.40	89.82
contains_text	77.15	26.70	90.27
tattoo_count	81.67	83.26	87.56
Media	76.92	64.43	85.84

Los resultados muestran diferencias claras entre los modelos evaluados. Qwen2-VL obtuvo la mayor precisión media global, alcanzando un 85.84 % de acierto, frente al 76.92 % de Moondream2 y al 64.43 % de LLaVA.

Las mayores diferencias aparecen en tareas que requieren una interpretación visual más detallada. En particular, Qwen2-VL obtuvo un 90.27 % de precisión en la detección de texto visible, superando ampliamente tanto a Moondream2 (77.15 %) como a LLaVA (26.70 %). También alcanzó los mejores resultados en la clasificación del color del tatuaje, la estimación de su tamaño relativo y el recuento de tatuajes visibles.

Por el contrario, la variable `has_tattoo` presentó valores muy elevados para los tres modelos, lo que indica que la detección básica de la presencia de tatuajes constituye una tarea considerablemente más sencilla que otras relacionadas con la interpretación de características específicas.

Aunque los porcentajes obtenidos por Qwen2-VL resultan elevados en la mayoría de las variables analizadas, la revisión manual de las predicciones mostró que continúan apareciendo errores claramente identificables en determinadas imágenes. Por este motivo, los resultados deben interpretarse como una evidencia del potencial actual de los modelos multimodales para asistir tareas de análisis visual, más que como una solución completamente fiable para escenarios operativos sin supervisión humana.

En conjunto, los resultados justifican la selección de Qwen2-VL como modelo principal para los análisis realizados en las siguientes secciones.

5.3.1. Análisis por variable

El análisis individual de cada variable permite comprender mejor qué tipos de tareas fueron más sencillas para los modelos evaluados y con cuáles tuvieron más dificultades.

5.3.1.1. Presencia de tatuaje

La detección de la presencia de tatuajes fue la tarea que produjo los mejores resultados en conjunto. Los tres modelos alcanzaron precisiones próximas al 100 %, lo que indica que la detección de la presencia de un tatuaje constituye una tarea relativamente sencilla cuando este resulta claramente visible en la imagen.

Las diferencias entre arquitecturas fueron mínimas, sugiriendo que esta capacidad se encuentra razonablemente consolidada incluso en modelos multimodales de menor tamaño.

5.3.1.2. Tamaño del tatuaje

Entre todas las tareas analizadas, la clasificación del tamaño fue la que presentó mayores dificultades. Incluso Qwen2-VL, que obtuvo el mejor rendimiento en esta tarea, alcanzó una precisión del 61.76 %.

A diferencia del resto de variables analizadas, la estimación del tamaño depende no solo del tatuaje en sí, sino también de la proporción de región corporal visible en cada imagen. Además, no existe una frontera completamente objetiva entre las categorías `small`, `medium` y `large`, por lo tanto, esta variable tiene cierto grado de subjetividad incluso durante el proceso de etiquetado manual.

Estos factores ayudan a explicar por qué la clasificación del tamaño resultó bastante más compleja que el resto de tareas evaluadas.

5.3.1.3. Presencia de color

La clasificación entre tatuajes monocromáticos y tatuajes con presencia de color mostró diferencias importantes entre modelos. Mientras que Moondream2 y LLaVA obtuvieron resultados idénticos, Qwen2-VL alcanzó una precisión cercana al 90 %.

Los errores observados aparecieron principalmente en imágenes donde el color estaba presente únicamente en pequeñas regiones o donde las tonalidades resultaban poco saturadas. En estos casos, incluso para un observador humano puede resultar difícil determinar con claridad la categoría correcta.

5.3.1.4. Presencia de texto

Las mayores diferencias de rendimiento aparecieron durante la detección de elementos textuales. Qwen2-VL alcanzó una precisión del 90.27 %, mientras que Moondream2 obtuvo un 77.15 % y LLaVA descendió hasta el 26.70 %.

Estos resultados indican que la capacidad de lectura visual que tiene Qwen2-VL es bastante superior a la observada en los demás modelos evaluados. Por el contrario, LLaVA mostró grandes dificultades para identificar correctamente texto presente en los tatuajes.

5.3.1.5. Número de tatuajes

La variable `tattoo_count` presentó resultados intermedios, con precisiones superiores al 80 % para las tres arquitecturas evaluadas.

Aunque los modelos fueron generalmente capaces de distinguir entre tatuajes únicos y múltiples, se detectaron errores en imágenes donde los diseños aparecían parcialmente visibles o muy próximos entre sí. En algunos casos, varios elementos que pertenecían a un mismo tatuaje se reconocieron como diferentes tatuajes, mientras que en otros ocurría el efecto contrario y distintos tatuajes eran considerados de un único diseño.

La Figura 5.3 permite visualizar de forma conjunta el rendimiento obtenido por cada modelo para las distintas variables evaluadas. Puede observarse que Qwen2-VL presenta los mejores resultados globales en la mayoría de las tareas analizadas.




Ilustración 5.3: Comparación de precisión entre los modelos evaluados para cada variable.

5.3.2. Selección del modelo final

Los resultados obtenidos muestran de forma consistente que Qwen2-VL fue el modelo con mejor rendimiento global entre las arquitecturas evaluadas. Además de alcanzar la mayor precisión media, obtuvo los mejores resultados en la mayoría de las variables analizadas, especialmente en aquellas relacionadas con la interpretación visual más compleja, como la detección de texto o la clasificación del color del tatuaje.

5.3.3. Análisis detallado de Qwen2-VL

Tras la comparación realizada entre los distintos modelos multimodales, Qwen2-VL obtuvo el mejor rendimiento global y fue seleccionado para un análisis más detallado.

El objetivo de esta sección consiste en identificar qué variables fueron más fáciles para el modelo, con cuáles tuvo mayores dificultades y qué tipos de errores aparecieron con mayor frecuencia.

La Figura 5.4 muestra la precisión obtenida por Qwen2-VL para cada una de las variables evaluadas.




Ilustración 5.4: Precisión obtenida por Qwen2-VL para cada variable evaluada.

Las variables relacionadas con la detección de tatuajes y la identificación de texto alcanzan los valores de precisión más elevados, mientras que la clasificación del tamaño constituye el principal desafío para el modelo.

Este comportamiento resulta coherente con la propia naturaleza de las tareas evaluadas. Mientras que la presencia de un tatuaje o de texto suele poder determinarse mediante patrones visuales relativamente claros, la estimación del tamaño depende en gran medida del contexto de la imagen y de la proporción ocupada por el tatuaje respecto a la región corporal visible.

5.3.3.1. Presencia de tatuaje

La detección de tatuajes fue la tarea que produjo los mejores resultados, alcanzando una precisión del 99.77 %.

Únicamente se registró una predicción incorrecta en todo el conjunto de evaluación, lo que confirma que esta es la tarea más sencilla de las analizadas.

5.3.3.2. Análisis de la variable `tattoo_size`

La clasificación del tamaño fue la tarea que presentó mayores dificultades para el modelo.

La Figura 5.5 muestra la matriz de confusión obtenida para esta variable.




Ilustración 5.5: Matriz de confusión para la variable `tattoo_size`.

La mayoría de los errores se producen entre categorías adyacentes, especialmente entre

`small` y `medium` o entre `medium` y `large`. Las confusiones directas entre las categorías extremas fueron considerablemente menos frecuentes.

Además, la categoría `medium` concentró buena parte de la incertidumbre observada. Muchos de los ejemplos etiquetados manualmente como tamaño medio fueron clasificados como pequeños o grandes, lo que sugiere que esta categoría representa una frontera visual especialmente difusa.

5.3.3.3. Análisis de errores por proximidad

La variable `tattoo_size` presenta una característica particular que no aparece en el resto de variables evaluadas. A diferencia de tareas binarias como la detección de texto o la presencia de tatuajes, las categorías `small`, `medium` y `large` poseen una relación ordinal natural.

Esto implica que no todos los errores tienen la misma relevancia. Por ejemplo, clasificar un tatuaje `small` como `medium` constituye un error razonable debido a la similitud visual entre ambas categorías, mientras que clasificarlo como `large` supone una discrepancia mucho más significativa.

Por este motivo se realizó un análisis complementario distinguiendo entre errores leves y errores más significativos.

Los resultados mostraron que una parte importante de las predicciones incorrectas correspondían a categorías adyacentes. En consecuencia, cuando se permite una tolerancia de una categoría de diferencia, la tasa efectiva de acierto aumenta de forma notable respecto a la precisión estricta.

Cuadro 5.3: Comparación entre precisión estricta y precisión con tolerancia para la variable `tattoo_size`.

Métrica	Valor (%)
Precisión estricta	61.76
Precisión con tolerancia de una categoría	95.02

Este resultado confirma que, aunque el modelo no siempre asigna la categoría exacta, generalmente produce estimaciones razonables del tamaño relativo de los tatuajes.

5.3.3.4. Análisis de la variable `contains_text`

La detección de texto visible fue una de las capacidades más sólidas observadas en Qwen2-VL.

La Figura 5.6 muestra la matriz de confusión correspondiente.




Ilustración 5.6: Matriz de confusión para la variable `contains_text`.

La mayoría de los ejemplos fueron clasificados correctamente, observándose errores sobre todo en textos pequeños, parcialmente visibles o integrados dentro de diseños complejos.

Durante la revisión manual también se observó una ligera tendencia a identificar como texto determinados símbolos o caracteres visualmente similares. A pesar de ello, la tasa de acierto obtenida fue elevada, lo que convierte esta variable en una de las más fiables dentro del conjunto analizado.

5.3.3.5. Análisis de la variable `tattoo_color`

La clasificación entre tatuajes monocromáticos y tatuajes con presencia de color mostró igualmente resultados elevados.

Los errores se concentraron principalmente en tatuajes donde el color aparece de forma limitada o poco saturada, situaciones que también pueden resultar ambiguas durante la revisión manual.

5.3.3.6. Análisis de la variable `tattoo_count`

La identificación del número de tatuajes visibles presentó resultados intermedios.

La mayor parte de los errores se produjo en imágenes etiquetadas como `multiple`. En numerosos casos el modelo tendió a interpretar varios tatuajes próximos entre sí como una única composición visual, clasificándolos erróneamente como `single`.

Estos errores sugieren que la principal dificultad radica en separar visualmente diseños independientes cuando aparecen próximos dentro de la misma imagen.

5.3.3.7. Errores más frecuentes

La revisión manual de las predicciones incorrectas permitió identificar varios patrones recurrentes. Una parte de los errores aparece en imágenes donde únicamente se observa una fracción reducida del tatuaje o donde el encuadre limita la información visual disponible. También se detectaron dificultades asociadas a condiciones de iluminación complejas, reflejos o contrastes reducidos.

Por otra parte, algunas variables presentan fronteras visuales poco definidas incluso para un observador humano. Este fenómeno resulta especialmente evidente en la clasificación del tamaño y, en menor medida, en la identificación de tatuajes coloreados cuando la presencia de color es limitada.

En general, los resultados muestran un comportamiento sólido para la mayoría de las tareas evaluadas. Sin embargo, la revisión manual permitió comprobar que siguen apareciendo errores evidentes en algunas imágenes. Por lo tanto, estos resultados deben interpretarse como una aproximación prometedora, aunque todavía insuficiente para sustituir completamente la revisión realizada por un especialista humano.

5.3.4. Evaluación cualitativa mediante preguntas abiertas

Además de las preguntas categóricas utilizadas durante la evaluación cuantitativa, se realizaron pruebas adicionales con preguntas abiertas dirigidas exclusivamente a Qwen2-VL.

El objetivo de estas pruebas no era obtener métricas de rendimiento, sino analizar la capacidad del modelo para generar descripciones más completas e integrar múltiples observaciones visuales dentro de una misma respuesta.

Las preguntas planteadas incluían aspectos como la descripción general de la escena, la localización y el tamaño del tatuaje, la identificación de estilos y motivos visuales, la detección de texto, la estimación de la complejidad visual y la explicación libre del contenido observado.

Los resultados obtenidos muestran que Qwen2-VL es capaz de producir respuestas considerablemente más detalladas que las generadas mediante tareas de clasificación, manteniendo en muchos casos una buena correspondencia con el contenido visual observado.

La Figura [5.7](#) muestra una de las imágenes utilizadas durante estas pruebas.



Ilustración 5.7: Ejemplo de tatuaje utilizado durante la evaluación mediante preguntas abiertas.

Scene Description

The image shows a person's shoulder and upper arm partially covered by clothing. A large tattoo depicting a fierce demonic figure with expressive eyes, sharp teeth and a flowing beard occupies the shoulder region. The composition contains multiple decorative details and presents a dark, visually complex appearance.

Model Interpretation

Tattoo detected: Yes. The image contains a single tattoo located on the shoulder. The tattoo is classified as large, coloured and visually complex. Its style corresponds to a complex illustration and the main motif is identified as a fantasy creature.

Motif Description

The tattoo appears to represent a detailed demonic figure with a menacing facial expression, prominent teeth and a flowing beard. The design contains several ornamental elements and exhibits a high degree of visual detail, resulting in a striking and easily recognizable composition.

Confidence

The model reports a high confidence level for the generated description.

En el ejemplo anterior se puede ver cómo el modelo combina distintos elementos visibles de la imagen para construir una descripción relativamente completa del tatuaje. En este caso, la respuesta identifica correctamente aspectos como el tamaño aproximado, la localización, la complejidad visual y la presencia de una figura claramente reconocible.

Las pruebas realizadas muestran que Qwen2-VL no solo es capaz de identificar atributos visuales concretos, sino también de generar descripciones más amplias cuando se le proporciona una mayor libertad durante la generación.

No obstante, durante la revisión manual se observó que la calidad de las respuestas no es uniforme para todas las imágenes. En tatuajes más complejos, abstractos o con información visual limitada siguen apareciendo ocasionalmente descripciones incompletas o interpretaciones incorrectas.

Los resultados muestran que los modelos multimodales actuales pueden generar descripciones útiles y relativamente detalladas de los tatuajes observados, aunque la calidad final de las respuestas continúa dependiendo tanto de la complejidad de la imagen como de las instrucciones proporcionadas al modelo.

5.4. Grado de consecución de los objetivos

Una vez finalizado el desarrollo del proyecto y analizados los resultados obtenidos, puede afirmarse que los objetivos planteados inicialmente fueron alcanzados de forma satisfactoria.

El desarrollo del extractor de características permitió obtener una representación estructurada de los tatuajes a partir de imágenes segmentadas. Aunque algunas de las características consideradas en las primeras fases tuvieron que descartarse por problemas de robustez o interpretabilidad, el resultado final proporcionó una base sólida para el resto del trabajo.

La generación automática de informes también alcanzó los objetivos previstos. Los resultados obtenidos muestran que la combinación de características explicables y modelos multimodales permite producir descripciones estructuradas y generalmente coherentes con la información visual disponible. Durante esta fase fue necesario realizar un proceso continuo de refinamiento de prompts para reducir interpretaciones no justificadas y mejorar la consistencia de las respuestas.

Por otra parte, las dificultades encontradas al trabajar con imágenes sin segmentaciones precisas dieron lugar a una segunda línea de trabajo centrada en la evaluación de modelos multimodales sobre imágenes reales. Esta adaptación metodológica permitió ampliar el alcance inicial del proyecto y obtener una visión más completa de las capacidades actuales de este tipo de modelos.

Finalmente, los experimentos realizados pusieron de manifiesto tanto el potencial como las limitaciones de los enfoques estudiados. Los resultados obtenidos muestran que los modelos multimodales pueden alcanzar niveles de rendimiento elevados en determinadas tareas, aunque siguen requiriendo mecanismos de control y supervisión cuando se pretende utilizarlos en contextos donde la fiabilidad y la explicabilidad resultan especialmente importantes.

En conjunto, el grado de consecución del proyecto puede considerarse satisfactorio. Además de alcanzar los objetivos inicialmente planteados, el trabajo permitió explorar nuevas líneas de análisis surgidas durante el desarrollo y obtener una comprensión más amplia del problema estudiado.

Capítulo 6

Conclusiones y trabajos futuros

6.1. Conclusiones

Este trabajo ha estudiado la aplicación de técnicas de visión artificial y modelos multimodales al análisis automático de tatuajes, prestando especial atención a la explicabilidad de los resultados obtenidos.

A lo largo del proyecto se desarrollaron dos enfoques complementarios. El primero se basó en la extracción de características explicables a partir de imágenes segmentadas, mientras que el segundo se centró en evaluar directamente modelos multimodales sobre imágenes reales de tatuajes.

Los resultados obtenidos muestran que es posible extraer de forma automática información visual relevante a partir de imágenes segmentadas y utilizarla para construir representaciones estructuradas de los tatuajes. Estas características permitieron describir aspectos observables de forma objetiva y sirvieron como apoyo para la generación de informes descriptivos.

También se comprobó que la incorporación de características explicables facilita la interpretación de los resultados generados por los modelos multimodales. Aunque estas características no eliminan las limitaciones propias de los modelos, sí proporcionan una referencia adicional que ayuda a justificar determinadas observaciones y aporta una mayor trazabilidad al proceso de análisis.

Durante el desarrollo se observó además la influencia que tiene el diseño de los prompts sobre la calidad de las respuestas generadas. El refinamiento progresivo de las instrucciones permitió reducir interpretaciones no respaldadas por la evidencia visual y mejorar la consistencia de los informes obtenidos.

Por otra parte, la evaluación realizada sobre imágenes reales permitió comparar distintas arquitecturas multimodales bajo las mismas condiciones. Los resultados mostraron diferencias claras entre modelos y permitieron identificar a Qwen2-VL como la alternativa con mejor rendimiento dentro de los experimentos realizados.

Uno de los hallazgos más interesantes de esta segunda parte del trabajo fue comprobar que los modelos multimodales son capaces de extraer información útil directamente a partir de imágenes completas, incluso cuando no se dispone de segmentaciones precisas del tatuaje. Este resultado surgió de forma natural durante el desarrollo y dio lugar a una línea de análisis que inicialmente no estaba tan definida dentro del proyecto.

Los experimentos realizados también sirvieron para identificar diferentes limitaciones. Algunas tareas resultaron más complejas que otras y, aunque los niveles de precisión obtenidos fueron bastante altos en varias de las variables analizadas, la revisión manual de los resultados mostró que siguen apareciendo errores que dificultan su utilización directa en entornos donde se necesita una fiabilidad muy elevada.

Los resultados muestran que los modelos multimodales ofrecen posibilidades interesantes para el análisis de tatuajes y que la combinación de características explicables y modelos visión-lenguaje constituye una aproximación útil para abordar este problema. Al mismo tiempo, el trabajo pone de manifiesto la necesidad de seguir investigando mecanismos que permitan aumentar la fiabilidad, la interpretabilidad y el control sobre las respuestas generadas por estos sistemas.

6.2. Trabajos futuros

Los resultados obtenidos durante este proyecto ponen de manifiesto diversas líneas de trabajo que podrían explorarse en investigaciones posteriores con el objetivo de ampliar las capacidades del sistema desarrollado y profundizar en algunas de las cuestiones identificadas durante el análisis.

Una primera línea de interés consiste en disponer de bases de datos que combinen imágenes reales con segmentaciones precisas. Durante el desarrollo se observó que las dos bases de datos utilizadas ofrecían ventajas complementarias: mientras que HDA permitía trabajar con máscaras de segmentación detalladas, Tattoo-YOLO proporcionaba imágenes más próximas a escenarios reales. La combinación de ambas características permitiría estudiar enfoques híbridos que integrasen las ventajas observadas en los dos conjuntos de datos.

Otra posible extensión consiste en ampliar el proceso de etiquetado manual incorporando múltiples anotadores independientes. Esto permitiría analizar el grado de acuerdo entre evaluadores y estudiar con mayor profundidad la subjetividad asociada a determinadas variables, especialmente aquellas relacionadas con la estimación del tamaño o la interpretación visual de ciertos elementos presentes en los tatuajes.

Desde la perspectiva multimodal, resultaría especialmente interesante evaluar modelos más recientes o explorar técnicas de ajuste fino (*fine-tuning*) especializadas en imágenes de tatuajes. Este enfoque permitiría analizar hasta qué punto el conocimiento específico del dominio puede mejorar el rendimiento observado en tareas de identificación y descripción visual.

Asimismo, los resultados obtenidos sugieren que existe margen para desarrollar meca-

nismos adicionales de explicabilidad aplicados a modelos multimodales. La incorporación de mapas de atención, explicaciones visuales o sistemas capaces de relacionar explícitamente las respuestas generadas con evidencias observables en la imagen podría contribuir a aumentar la confianza y trazabilidad de los resultados.

Otra línea de trabajo especialmente relevante consistiría en validar el sistema con especialistas del ámbito forense. La participación de expertos permitiría valorar la utilidad práctica de las características extraídas, la calidad de los informes generados y la relevancia de la información proporcionada por los modelos dentro de escenarios de uso reales.

Por último, los resultados obtenidos durante la evaluación multimodal sugieren que los modelos actuales son capaces de extraer información útil directamente a partir de imágenes completas, incluso sin disponer de segmentaciones precisas. Este hallazgo abre la puerta al desarrollo de sistemas más integrados que combinen detección, análisis visual y generación automática de descripciones dentro de un único flujo de trabajo.

En conjunto, estas líneas de trabajo muestran que la investigación realizada constituye un punto de partida sobre el que continuar desarrollando sistemas más robustos, explicables y adaptados a las necesidades del análisis forense de tatuajes.

6.3. Uso de la Inteligencia Artificial

La inteligencia artificial ha estado presente en distintas fases de este Trabajo Fin de Grado. Principalmente como objeto de estudio, y también herramienta de apoyo durante para su desarrollo.

Por un lado, los modelos multimodales constituyen una parte fundamental del proyecto, ya que gran parte del trabajo se ha centrado en analizar su capacidad para interpretar imágenes de tatuajes y generar respuestas en lenguaje natural.

Por otro lado, también se utilizaron herramientas de inteligencia artificial como apoyo durante tareas concretas de desarrollo y redacción. Estas herramientas se emplearon principalmente para resolver algunas dudas de programación, corregir errores, contrastar distintas alternativas de implementación y consultar información técnica a cerca de los modelos y técnicas utilizadas.

Durante la elaboración de la memoria también se utilizaron como apoyo para revisar la redacción de algunos apartados, mejorar la claridad de determinadas explicaciones y ayudar en la organización de los contenidos.

Sin embargo, cabe recalcar que el diseño de la metodología, la implementación de los distintos sistemas desarrollados, la realización de los experimentos, el análisis de los resultados y las conclusiones obtenidas corresponden al trabajo realizado por el autor.

Bibliografía

- [1] Adadi, A. and Berrada, M. (2018). Peeking inside the black-box: A survey on explainable artificial intelligence (xai). *IEEE Access*, 6:52138–52160.
- [2] Gonzalez-Soler, L. J. et al. (2024). Tatttrn: Template reconstruction network for tattoo retrieval. In *CVPR Workshops*.
- [3] Gonzalez-Soler, L. J., Fischer, D., and Busch, C. (2023a). Hda semi-synthetic tattoo database. Dataset.
- [4] Gonzalez-Soler, L. J., Rathgeb, C., and Fischer, D. (2023b). Semi-synthetic data generation for tattoo segmentation. In *International Workshop on Biometrics and Forensics (IWBF)*, pages 1–6.
- [5] Harris, C. R. et al. (2020). Array programming with numpy. *Nature*, 585:357–362.
- [6] Hunter, J. D. (2007). Matplotlib: A 2d graphics environment. *Computing in Science and Engineering*, 9(3):90–95.
- [7] Korrapati, V. (2024). Moondream2. Hugging Face Model Card.
- [8] Liu, H., Li, C., Wu, Q., and Lee, Y. J. (2023). Visual instruction tuning. *Advances in Neural Information Processing Systems*.
- [9] Paszke, A. et al. (2019). Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*.
- [10] Wang, P. et al. (2024). Qwen2-vl: Enhancing vision-language model’s perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*.
- [11] Wolf, T. et al. (2020). Transformers: State-of-the-art natural language processing. In *EMNLP System Demonstrations*, pages 38–45.